

## LLM 을 어떻게 사용해야 하는가?: 스승, 동료, 일꾼으로

저자 소개:

- 정갑주 (jeongk@konkuk.ac.kr & karpjoo@gmail.com)
- 소속:
  - 건국대학교 컴퓨터공학과
  - 인간 중심 스마트 인프라 연구소

유의사항:

1. 모든 강의자료는 **저자의 개인적 지식, 경험 및 의견**을 토대로 작성되었습니다.
  - 그러나 AI 기술이 많은 기업과 전문가들에 의해서 비약적으로 발전하고 있는 상황에서 저자 혼자서 알 수 있는 것은 솔직히 매우 제한적일 수밖에 없습니다. 따라서 더 이상 의미가 없는 과거 기술에 대한 설명, 최신 기술에 대한 잘못된 해석, 충분히 인정받지 못한 주관적 견해들이 포함되어 있을 수 있습니다.
  - 최대한 객관적이고 정확하게 설명하려고 노력은 했지만, 현 시점의 AI 기술 상황에서는 한계가 있을 수밖에 없었다는 핑계로 양해를 구합니다.
2. 모든 강의자료의 주제와 내용은 저자가 직접 결정한 것들입니다. 그러나 **포함된 참고 자료, 사례조사 및 예시는 LLM 을 사용해서** 만들었습니다.
  - 그런데 LLM 은 사실이 아닌 것을 그럴싸하게 지어내는 실수 (환각) 를 자주 합니다. 따라서 강의자료의 참고자료, 사례, 및 예시에 오류가 있을 수 있습니다.
  - 그런 LLM 의 실수는 모든 출처를 철저히 조사해야만 확인이 가능한데, 현재 강의 자료를 만들고 있는 과정이라 아직 완전한 검증을 못 했습니다. 혹시 오류가 있다면 미리 이해를 구합니다. 오류는 저자에게 알려주시길 부탁드립니다.

---

### 목적 및 핵심 요약

이 강의자료가 답하려는 질문은 하나입니다.

- **인류 역사상 존재한 적이 없는 지적 능력을 가진 존재가 지금 내 앞에 있습니다. 나는 그것을 어떻게 사용해야 할까요?**

핵심 요약은 다음과 같습니다.

- LLM 은 거의 모든 분야에서 최고 전문가 수준의 지식을 갖고 있고, 이제는 그 지식을 활용해서 문제를 푸는 능력까지 빠르게 갖춰가고 있습니다. 인간은 이런 존재가 될 수 없습니다.
- 그런데 그 능력은 **저절로 나오지 않습니다**. 세 가지 구조적 제약—인간 우선 원칙의 역설, 지식의 양의 역설, 효율의 역설—때문입니다.
- 이 셋은 **LLM 의 결함이 아니라 LLM 의 제약**입니다. 알고 대처하면 문제가 되지 않지만, 모르고 쓰면 영성할 결과 또는 실제 피해를 보게 됩니다.
- 그 제약을 다루는 가장 실용적인 방법이 **LLM 을 스승·동료·일꾼 중 하나로 정하고 대화하는 것**입니다.

## 1. LLM 은 얼마나 똑똑할까요?

이 장의 주장은 하나입니다.

- **LLM 은 인류 역사상 존재한 적이 없는 유형의 지적 능력을 가진 존재입니다.**

“똑똑하다”를 두 축으로 나눠서 확인해 보겠습니다.

- **지식의 양:** 얼마나 아는가?
- **지식의 활용 능력:** 아는 것으로 무엇을 할 수 있는가?

### 1.1 지식의 양—거의 모든 분야에서“최고 전문가 수준”

#### (1) 학습의 규모

최신 LLM 은 **Pre-Training(사전 학습)** 에 조 (兆) 단위의 토큰을 씁니다. 공개된 모델 사양에는 **15 조 토큰 규모**의 말뭉치가 등장합니다.

- 토큰은 대략 **단어 조각** 하나입니다. 한국어로는 한두 글자, 영어로는 짧은 단어 하나 켜 됩니다.
- 감을 잡기 위한 환산입니다 (**정확한 비교는 아닙니다**).

| 기준                 | 대략의 분량                 |
|--------------------|------------------------|
| 300 쪽짜리 단행본 1 권    | 약 10 만 토큰              |
| 15 조 토큰            | <b>책 1 억 5 천만 권 분량</b> |
| 사람이 평생 (80 년) 읽는 양 | 아무리 많이 읽어도 수천 ~1 만 권   |

- 사람의 독서와 모델의 학습은 작동 방식이 다르고, “많이 학습했다”가 곧 “잘 안다”도 아닙니다.
- 그래도 **양적 차이가 네다섯 자릿수 단위 (1 만 배 이상)** 라는 사실은 분명합니다.

#### (2) 학습의 범위

Pre-Training 에서 LLM 은 특정 분야만 골라 학습한 것이 아니라, **인간이 글로 기록한 것 전반**을 학습했습니다.

- 백과사전, 뉴스, 논문, 교과서, 매뉴얼, 법령, 기술 문서, 코드 저장소, 토론 게시판, 문학 작품 등 **글로 기록된 것의 대부분**입니다.
- 그리고 **지금도 모델 세대 단위** (예: ChatGPT-3, ChatGPT-4, ChatGPT-5 등) 로 **사전 학습은 계속되고 있습니다**. 모델 세대가 바뀔 때마다 학습 자료의 양과 질이 함께 급격히 올라갑니다.
- 약간의 과장을 허용하면, LLM 은 **인류 문명의 기록 대부분을 아는 수준의 지식**을 갖고 있습니다.

#### (3) 그래서 넓이가 이 정도입니다

사람 전문가는 **한 분야**에 집중합니다. 두 분야를 깊이 아는 사람은 드물고, 그 이상을 아는 전문가는 사실상 없습니다.

- 그러나 LLM 은 깊이와 넓이를 **동시에** 갖고 있습니다.

| 영역       | 예                          |
|----------|----------------------------|
| 자연과학     | 물리·화학·생물·지구과학의 학부 ~ 대학원 수준 |
| 의학·보건    | 질병, 약물 상호작용, 검사 수치 해석의 일반론 |
| 법·행정     | 법 개념, 계약 구조, 행정 절차의 일반론    |
| 경제·금융·회계 | 재무제표, 세제 개념, 금융 상품 구조      |
| 공학 전반    | 기계·전기·건축·화공의 기본 원리         |
| 소프트웨어    | 수십 종의 프로그래밍 언어와 라이브러리      |
| 인문·예술    | 역사, 철학, 문학, 음악 이론, 미술사     |
| 언어       | 수십 ~ 수백 개 언어의 번역과 문체       |
| 실무 지식    | 문서 양식, 협상, 프로젝트 관리, 교육 방법론 |

#### 핵심:

- 어떤 문제에 관해서도, 그 분야에 관한 상당한 지식이 이미 LLM 안에 있습니다.

### 1.2 지식의 활용 능력—“아는 것”에서“푸는 것”으로

“많이 안다”와 “전문가 수준으로 문제를 푼다”는 완전히 다른 이야기입니다. 그래서 연구자들은 **검색으로는 절대 못 푸는 문제로** 시험합니다.

#### (1) 검색으로는 안 되는 시험: GPQA

생물·물리·화학 분야의 박사급 전문가들이 직접 출제한 448 문항으로, 해당 분야의 박사 학위 소지자나 박사 과정생이 65% 를 맞습니다. 반면 다른 분야의 우수한 인력이 인터넷을 마음껏 쓰면서 문항당 평균 30 분 넘게 붙잡고도 34% 밖에 못 맞습니다.

이 시험이 중요한 이유는, “어떤 분야에서 자료를 찾아오는 능력”과 “그 분야를 이해하고 추론하는 능력”을 분리해서 측정하기 때문입니다. 34% 와 65% 의 간격이 바로 그 분리입니다.

#### (2) 3 년 만에 벌어진 일

(모델 점수는 가장 어려운 198 문항 세부 집합 (Diamond) 기준이고, 인간 점수는 448 문항 전체 집합 기준입니다.)

| 기준                   | 정답률        |
|----------------------|------------|
| 무작위로 찍기              | 25%        |
| 인터넷 쓰는 비전문가          | 34%        |
| <b>해당 분야 박사급 전문가</b> | <b>65%</b> |
| 2023 년 11 월, GPT-4   | 35.7%      |

| 기준                        | 정답률      |
|---------------------------|----------|
| 2024 년 3 월, Claude 3 Opus | 약 50~60% |
| 2025~2026 년 주요 모델         | 80~90% 대 |

### (3) 이것이 의미하는 것

- 무작위 찍기처럼 보였던 초기 수준에서 시작해 **전문가 평균을 넘어서는** 데 약 3 년이 걸렸습니다.
- 비슷한 일이 의학, 법학, 회계, 공학 등 여러 분야의 시험에서 반복 관측됐습니다.
- 특정 분야에서만 우연히 잘하는 게 아니라, **LLM 이 자료를 학습한 분야** 거의 전부에서 나타나는 현상입니다. 물론 그 분야의 많은 지식들이 이미 문서 자료로 축적되었고 LLM 이 그것을 학습한 경우에 한해서입니다.

### (4) 최근에 빨라진 이유

지식의 양은 Pre-Training(사전 학습의 양) 에서 옵니다. 그러나 **활용 능력**은 그 다음 단계에서 옵니다.

- 최근 모델 개발의 무게중심이 **“더 많이 읽히기”에서 “더 잘 풀게 만들기”로 이동**했습니다.
- 대표적인 것이 **추론 (reasoning) 강화 학습**입니다. 답을 바로 내놓는 대신, 중간 사고 과정을 길게 전개하고 **정답 여부로 그 과정을 훈련**시킵니다.
- 그 결과 수학·과학·코딩처럼 **정답을 기계적으로 채점할 수 있는 분야**에서 성능이 특히 가파르게 올랐습니다.

### (5) 여기서 미리 기억해 둘 것:

- 성능이 빨리 오른 분야는 공통점이 있습니다. — **정답을 확인할 수 있는 분야**입니다. 이 사실은 이 강의 전체의 밑바닥에 깔린 원리이고, 4 장과 5 장에서 다시 나옵니다.

### (6) 경고: 단, 벤치마크 숫자는 조심해서 읽어야 합니다

능력을 정확히 알려면 **과장도 걷어내야** 합니다.

- 2023 년 GPT-4 가 미국 변호사 시험에서 보여준 성능 결과가 크게 보도됐습니다.
  - 처음에는 **“상위권 10%”** (90 번째 백분위) 라고 보도되었습니다.
  - 그런데 이후 재분석에서 그 수치가 채용시자 비중이 높은 2 월 시험 기준이라는 점이 지적됐습니다.
  - 전체 응시자와 비교하면 **69 번째 백분위 (상위 약 31%)** 정도이고, 논술은 **48 번째 백분위 (중간 정도)** 였습니다.
  - 초시 응시자 기준으로는 **62 번째 백분위 (상위 약 38%)** 정도였고,
  - 실제로 시험에 합격한 사람들 (즉 변호사) 만 놓고 보면 **48 번째 백분위 (중간 정도)** 이고, 논술은 **15 번째 백분위 (최하위권)** 로 떨어진다는 추정이 나왔습니다.

**“상위 10%”**성과 **“합격자 중 하위권”**은 완전히 다른 이야기입니다.

여기서 얻을 교훈이 두 가지 있습니다.

- 벤치마크 숫자는 **누구와 비교했는지**를 봐야 합니다.
- 그럼에도, **시험을 통과하는 수준의 지식이 실제로 들어 있다**는 사실 자체는 변하지 않습니다.

능력을 과대평가하는 것도, 과소평가하는 것도 **둘 다 잘못 이해하는 것입니다.**

### 1.3 어떤 의미일까요?

#### (1) 이미 도달한 수준

LLM 은 이미 다양한 분야에서 **인간에 필적하는, 어쩌면 이미 초월한 수준**의 지적 능력에 도달했습니다. 그리고 거기서 멈추지 않고 **지적 수준에서는 거의 만능인 존재**로 빠르게 발전하고 있는 것으로 보입니다.

**경고: 여기서 정확히 구분해야 할 것**

- “여러 분야의 시험에서 전문가 평균을 넘었다”는 **관측된 사실**입니다.
- “곧 거의 만능이 된다”, “초인공지능 시대가 열린다”는 **아직 논쟁적인 예견**입니다. 연구자들 사이에서도 시점과 가능성에 대한 견해차가 큼니다.
- 이 강의는 앞의 사실 위에서 진행되며, 뒤의 예견은 **가능성으로만** 다룹니다.

#### (2) 그런데 인간은 이런 전문가가 될 수 없습니다

여기가 이 장의 진짜 요점입니다. LLM 의 지적 능력이 새로운 이유는 **수준**이 아니라 **형태** 때문입니다.

인간은 둘 중 하나만 할 수 있습니다.

| 인간의 두 경로              | 결과                               |
|-----------------------|----------------------------------|
| <b>얕게, 다양하게 많이 알기</b> | 넓지만 알습니다. 어느 분야에서도 전문가 판단을 못 합니다 |
| <b>한 분야를 깊게 알기</b>    | 깊지만 좁습니다. 그 분야를 벗어나면 비전문가입니다     |

**동시에 둘 다를 하는 것은 인간에게 가능하지 않습니다.** 수명, 기억 용량, 학습 속도가 모두 유한하기 때문입니다.

- 인류 역사에서 이 유형에 가장 가까웠던 사람으로 흔히 아리스토텔레스가 거론됩니다. 논리학, 형이상학, 생물학, 윤리학, 정치학, 시학을 모두 저술했습니다.
- 그러나 그것도 **당시 축적된 지식의 총량이 한 사람이 감당할 만했기 때문에** 가능했던 일입니다.
- 지식이 폭증한 이후로는 그런 인물이 다시 나오지 않았습니다. **수천 년 인류 문명사에 사실상 없었다고 보아야 합니다.**

#### (3) 그래서 결론입니다

인류 역사상 처음으로 LLM 과 같은 존재가 나타났습니다.

- LLM 은 **넓이 × 깊이**를 동시에 갖춘 지적 존재입니다.
- 인간에게는 구조적으로 불가능한 지식을 갖춘 존재입니다.

우리는 인류가 한 번도 다뤄본 적 없는 종류의 도구를 손에 쥐고 있습니다.

- 그런 기술 또는 존재를 어떻게 사용하는지에 대한 축적된 지혜가 없다는 뜻이기도 합니다. 2 장은 그 결과를 다룹니다.
- 

## 2. 우리는 LLM 을 잘 사용하고 있을까요?

1 장의 결론이“엄청난 능력”이었다면, 이 장의 결론은 이것입니다.

- 우리는 그 엄청난 능력의 아주 일부만 쓰고 있어서 손해를 많이 보고 있습니다.
- 그리고 경우에 따라 잘못 사용해서 심각한 피해를 봅니다.

### 2.1 현재 일반적인 활용 수준

#### (1) 넓게 퍼졌지만, 얇게 쓰입니다

추측 대신 실제 사용 데이터를 보겠습니다. Anthropic 은 자사 서비스의 대화를 미국 노동부의 직업 과제 분류 (O\*NET) 에 대응시켜 정기적으로 공개하고 있습니다.

- **넓은 사용 수준:** 2026 년 2 월 기준, 표본에 포함된 직업의 49% 가 자기 업무 과제의 4 분의 1 이상에 AI 를 쓴 것으로 나타났습니다. 2025 년 1 월의 36% 에서 올라간 수치입니다.
- **얇은 사용 수준:** 반대로 보면, O\*NET(미국의 대표적인 표준 직업 정보 데이터베이스) 의 약 18,000 개 과제 중 측정 가능한 사용이 실제로 관측된 것은 7.5% 에 불과합니다.

두 숫자가 동시에 참입니다.

- 많은 곳에서 도입하려고 시도는 하고 있습니다.
- 그러나 제대로 도입 효과를 보는 곳은 아직 드뭅니다.

1 장에서 본“거의 모든 분야를 아는 존재”와 비교하면 격차가 분명합니다. **능력의 범위는 거의 전 분야인데, 실제 사용은 7.5% 의 과제에 몰려 있습니다.**

- 사용이 몰려 있는 곳은 컴퓨터·수학 직군, 교육·도서관 직군, 영업 직군이고, 물리적 작업이 중심인 직군은 맨 아래에 있습니다.
- 특히 컴퓨터·수학 관련 과제는 일반 대화의 약 35%, API 트래픽의 절반 가까이를 차지합니다.

#### (2) 그래도 일상으로 넘어오고는 있습니다

- 가장 많이 요청되는 상위 10 개 과제의 비중은 2025 년 11 월 24% 에서 2026 년 2 월 19% 로 줄었습니다. 다른 과제들로도 확장되고 있다, 즉 쓰임새가 넓게 퍼지고 있다는 뜻입니다.
- 예를 들어, 같은 기간 스포츠 경기 결과, 제품 비교, 집수리 같은 개인적 용도는 35% 에서 42% 로 늘었습니다.

- 미국의 세금 신고 마감일인 4 월 14~15 일에는 세무 관련 대화가 평균의 몇 배로 치솟았다가 마감 후 곧바로 가라앉았습니다.

마지막 사례가 중요합니다. 사람들은 이제 LLM 을 “재미있는 챗봇”이 아니라 **실제 의사결정에 쓰고 있습니다**. 확인 없이 쓰면 피해가 나는 영역으로 이미 들어와 있다는 뜻입니다.

### (3) 잘못된 활용, 그리고 실제 피해

그러나 이것이 더 중요합니다. 잘못된 사용은 단순한 비효율이 아니라 **실제 피해**로 이어집니다. 가장 잘 기록된 사례가 법조계에서 나왔습니다.

- 2023 년 6 월, 뉴욕의 한 변호사가 존재하지 않는 판례 6 건을 법원에 제출했습니다. LLM 에게 근거 판례를 찾아달라고 했더니 인용구와 사건 번호까지 완비된 그럴듯한 판례가 나왔고, 그는 확인 없이 그것을 제출했습니다. 법원은 5,000 달러의 제재를 부과했습니다.

문제는 이게 **한 번의 해프닝이 아니었다는 것**입니다.

| 시점           | LLM 이 만든 가짜 인용이 포함된 누적 법원 사건 수 |
|--------------|--------------------------------|
| 2025 년 중반    | 약 200 건                        |
| 2026 년 1 월   | 719 건                          |
| 2026 년 4 월 초 | 1,227 건                        |
| 2026 년 6 월   | 1,598 건                        |

(출처: AI 환각 관련 법원 제재 동향 집계.)

- 2026 년 2 월에는 한 변호사가 제출한 서면의 인용 63 건 중 57 건에 문제가 있었습니다. 존재하지 않는 판례 20 건, 조작된 결정문 3 건, 없는 법조문 인용이 포함되어 있었고, 해당 주 대법원은 그를 정직 처분했습니다.

그리고 이걸 “비전문적인 도구를 써서 그렇다”는 이야기가 아닙니다. 전문 법률 조사 도구조차 17~33% 의 확률로 환각을 일으킨다는 연구 결과가 있습니다.

### (4) 진짜 교훈:

- 이 사람들은 LLM 을 **안 써서** 손해 본 게 아닙니다. **확인 없이 써서** 피해를 봤습니다.
- 법조계만의 이야기가 아닙니다. 의료 정보, 세무 판단, 계약 검토, 투자 결정, 학교 과제—**결과를 확인하지 않는 순간 같은 일이 벌어집니다**.
- 정리하면 이렇습니다. **확인할 수 없는 것은 시킬 수 없습니다**. 자동화의 범위가 검증의 범위를 넘어가는 순간, 얻는 것은 성과가 아니라 **위험**입니다.

## 2.2 제대로 활용하지 못하는 이유

이유는 여럿이지만, 저자가 가장 중요하다고 보는 것은 **세 가지 역설**입니다. 셋 다 “LLM 이 잘 작동하기 위해 갖춘 성질”이 동시에 “**사용을 어렵게 만드는 원인**”이 된다는 구조를 갖습니다. 그래서 역설입니다.

### (1) 인간 우선 원칙의 역설

LLM 은 **인간의 뜻을 따르는 것을 최우선으로** 설계·훈련되어 있습니다. 사용자가 요청한 것을 하고, 요청하지 않은 것은 하지 않습니다.

- 그래서 **요청의 범위를 벗어나거나 요청을 보완하지 않습니다.**
- 세상의 모든 전문 서적이 있지만 **사서가 없는 도서관**과 같습니다. “당신이 지금 찾는 건 3 층 오른쪽 서가에 있고, 그 전에 이 책을 먼저 봐야 합니다”라고 말해주는 사람이 없습니다.
- 내가 **요청한 책만** 나옵니다. 내가 **요청할 줄 아는 만큼만** 말입니다.

| 내가 한 요청       | 내가 받는 결과                                   |
|---------------|--------------------------------------------|
| 요청하지 않은 것     | <b>없습니다</b> (안에 있는데도 안 나옵니다)               |
| 애매하게 요청한 것    | 애매한 응답, 또는 <b>LLM 이 자기 마음대로 판단해서 만든 응답</b> |
| 잘못된 전제로 요청한 것 | <b>그 오류를 전제로 해서</b> 만든 응답                  |
| 정확히 요청한 것     | 놀라운 수준의 응답                                 |

이러한 특징 때문에 LLM 은 **두 가지 문제**를 발생시킵니다.

① **동조 경향**: 이 성질의 가장 위험한 형태입니다.

>> 나:  
이 방향으로 가려는데 맞지?  
>> LLM:  
네, 좋은 접근입니다! 이유는...

마치 간신이 아첨하는 것과 비슷합니다.

- 질문 대상에 무관하게 “맞지?”라고 물으면 대체로 “맞다”고 답합니다.
- 이걸 대화가 아니라 **확신 증폭기**입니다. 내 생각이 검증받는 게 아니라 **강화됩니다.**

LLM 이 이런 식으로 응답하는 것은 사실 LLM 이 거짓말을 하는 것이 아닙니다.

- 이런 경향의 일차적 원인은 **사람의 선호를 반영해 훈련하는 과정 (RLHF 등)**에 있습니다. 사람들은 자신의 의견에 동의해 주는 답변을 더 좋게 평가하는 경향이 있고, 그 선호가 모델에 그대로 학습됩니다.
- 여기에 한 가지가 더 겹칩니다. **인간이 생각할 수 있는 거의 대부분의 주장은 100% 틀린 경우가 드뭅니다.** 아주 낮은 확률로, 아주 드문 상황에서는 맞을 수 있기 때문입니다. LLM 은 그런 예외적 가능성까지 알고 있기 때문에, “맞다”고 답할 여지를 언제나 찾아낼 수 있습니다.

② **동조 경향의 다른 부작용**

사람이 LLM 의 긍정적이고 아첨하는 답변을 그대로 받아들이면, **자신이 무엇을 모르고 있는지, 무엇을 잘못 알고 있는지를** 알 수 없게 됩니다.

- 따라서 사람이 발전하거나 개선될 기회를 얻을 수 없게 됩니다.
- 더 심각한 문제는 잘못 알고 있는 것을 LLM 이 동의해 주기 때문에 **오류에 대한 확증 편향**이 발생하게 된다는 점입니다.

그리고 또 하나의 형태가 “**모르는 것은 요청할 수 없다**”는 문제입니다.

예를 들어, 어떤 분야에서 일하고 있는 사람이 “자신이 서명한 계약서 내용을 LLM에게 확인”받으려 한다고 가정해 보겠습니다.

- 그는 그 계약을 당연히 1 회성 계약으로 알고 있습니다.
  - >> 사람 ([“미묘하게 표현된 자동 갱신 조건”이 포함된 계약서]를 제시하면서):  
'내가 이런 의도로 계약을 했고, 이것이 계약서야, 문제가 있는지 검토를 부탁해.'
  - >> LLM:  
'적절합니다.' (자신감 있게)
- 이 사람이 **자동 갱신** 개념을 알지 못해서 그 부분을 짚어 묻지 않았다면, LLM은 사용자가 설정한 좁은 초점 (내 의도대로 되어 있는가) 안에서만 검토하고 문제가 없다고 답할 가능성이 높습니다.
- LLM은 자동 갱신으로 인한 많은 문제점을 알고 있지만, 요청의 범위가 좁으면 그 지식이 응답에 등장하지 않습니다.
- 계약서에서 “자동 갱신 조건이 숨어 있는지”를 물으려면, 사람이 **자동 갱신이라는 개념을 이미 알고 있어야 합니다.**

최신 LLM 모델들은 추론 및 응답에 관해 많이 개선되고 있기 때문에 최신 모델에게 질문을 하면 좀더 적극적으로 답변할 가능성도 있습니다.

- 그러나 이런 개선에도 불구하고 LLM의 이런 불확실성은 계속해서 문제로 남게 됩니다.

#### 중요한 요점:

- 지식은 안에 있는데, **그 존재를 모르면 못 꺼냅니다.**
- 많은 사람들이 그 문제를 경험하고 있지만, **그 문제가 있는지조차 알지 못합니다.**

#### (2) 지식의 양의 역설

1장에서 본 **LLM의 장점인 “넓이 × 깊이”**가 여기서도 문제가 됩니다.

LLM은 한 주제에 대해 **너무 다양한 관점의 지식과 너무 깊은 수준의 지식을 동시에** 갖고 있습니다. 그래서 인간이 질문을 하면 이런 상태가 됩니다.

- 어떤 **관점**으로 답해야 하는가? (기술적? 법적? 경제적? 윤리적?)
- 어떤 **수준**으로 답해야 하는가? (중학생? 학부생? 실무자? 연구자?)
- 어떤 **목적**의 답인가? (배우려고? 판단하려고? 결과물이 필요해서?)

사람은 아는 게 하나면 그것을 말합니다. LLM은 **수십 가지 답변이 모두 가능**하기 때문에, 사용자가 정해주지 않으면 **스스로 고릅니다.**

- 문제는 **LLM이 일관성이 없기 때문에 (확률적 생성이 갖는 본질적 특징)** 사람이 명확하게 정해 주지 않으면 이랬다 저랬다 하게 된다는 점입니다.

>> 사용자: “우리 팀 회의록 정리해줘”

이 한 문장이 LLM에게 떠넘기는 결정들입니다.

- 누구를 위한 정리인가? (참석자용? 불참자용? 상급자 보고용?)
- 결정 사항만? 논의 과정도?

- 아직 안 정해진 것은 어떻게 표시하나?
- 발원자 이름을 남기나?
- 분량은?

여기서 **조용한 모호성 (silent ambiguity)** 이라 부르는 문제가 발생합니다. 가장 흔하고 가장 안 보이는 실패입니다.

- LLM 은 이 모호한 결정들에서 **뭘 골랐는지 말해주지 않습니다**. 알아서 그럴듯한 걸 고르고, 결과물은 그럴싸하게 잘 만듭니다.
- 어떨 때는 **읽어보면 매우 괜찮습니다**. 신뢰감이 생깁니다.
- 그런데 다음 주에 “아직 안 정해진 걸 정해진 것처럼 포함시킨다” 또는 “틀린 내용을 적어놓는다”는 문제가 터집니다. 사람이 신뢰를 하고 있으면 검증 없이 그대로 받게 됩니다.

**핵심:**

- 지식이 많을수록 “무엇을 원하는지 말해주지 않으면 알 수 없는” 상태가 심해집니다. **아는 게 많아서 생기는 문제입니다**.
- “읽어보면 매우 괜찮다”와 “없는 것을 또는 틀린 것을 응답한다”는 두 가지 모습이 동시에 LLM 에게 보이는 이유는 두 가지 원인이 결합되어 있기 때문입니다.
  - LLM 이 **온갖 종류의 지식**을 알고 있습니다.
  - LLM 은 **확률적으로 답변**을 생성합니다.

### (3) 효율의 역설

LLM 은 응답을 만들 때 **불필요하게 길어지지 않도록** 조정되어 있습니다. 사용자가 명시적으로 요청하지 않으면, 보통 **적당한 길이의 무난한 답변**을 내놓습니다.

- 물어본 것에 대한 **가장 표준적인 답**을 줍니다.
- “반대 의견, 놓친 전제, 대안, 위험 요소”는 **요청하지 않으면 불지 않습니다**.
- 그래서 사용자는 **“이 정도가 LLM 의 최대치구나”**라고 오해하게 됩니다. 실제로는 **요청의 최대치**였을 뿐입니다.

같은 질문, 다른 요청으로 확인해 보겠습니다.

- >> 요청 A:  
“이 사업 계획 어때?”
- >> LLM:  
장점 3개, 단점 2개, 마무리 한 문단. (5초 읽으면 끝. 별 도움 안 됨.)
- >> 요청 B:  
“이 계획이 실패한다면 가장 가능성 높은 원인 7가지를 확률 순으로. 격려는 하지 말고, 각각에 대해 지금 확인할 수 있는 방법도 같이.”
- >> LLM:  
..... (내가 생각 못 한 것 3~4개가 반드시 나온다.)

**같은 모델, 같은 대화창입니다.** 차이는 요청뿐입니다.

LLM 이 이런 식으로 답변하는 이유는 **과하게 장황한 응답보다 간결한 응답을 선호하도록 학습·정렬된 결과**에 가깝습니다.

- 실제 많은 경우에 사용자는 **장황하게 긴 설명** (“읽는 게 귀찮다”) 보다는 **짧고 간결한 응답**을 선호하기 때문입니다.
- 그래서 LLM 은 그런 식으로 응답하도록 훈련되어 있습니다.

#### (4) 통합 정리:

세 역설을 합치면 이렇습니다.

- ① 요청한 것만 한다 -> 요청 못 한 것은 영원히 안 나온다
  - ② 너무 많이 알고 있다 -> 관점·수준을 안 정해주면 임의로 고른다
  - ③ 무난하게 답하려 한다 -> 요청이 약하면 답도 약하다
- => LLM의 지식 크기와 능력 수준에 무관하게, 요청의 품질이 결과의 상한을 정한다.

도서관이 아무리 좋은 책을 많이 갖고 있어도, **내가 아는 제목의 책만 빌릴 수 있습니다.**

#### (5) 문제의 본질: 사용자의 요청

그리고 이것은“LLM 의 문제”가 아니라 **인간이 그렇게 요청했기 때문**입니다.

이 점이 매우 중요합니다.

| 잘못된 이해            | 정확한 이해                       |
|-------------------|------------------------------|
| LLM 이 게을러서 대충 답한다 | 요청이 무난해서 무난하게 답했다            |
| LLM 이 아첨꾼이라 못 믿는다 | 인간 우선 원칙의 결과다. 반대를 요청하면 반대한다 |
| LLM 이 멋대로 지어낸다    | 요청이 모호했고, 그 빈칸을 채운 것이다       |

세 역설은 **LLM 의 결함 (bug) 이 아니라 LLM 의 제약 (constraint) 입니다.**

- 이 제약들은 **LLM 이 유용하기 위해 설계된 성질**이기도 합니다.
- **인간의 뜻을 따르지 않는 LLM, 아는 게 적은 LLM, 매번 논문 분량으로 답하는 LLM** 을 원하는 사람은 없습니다.

따라서 지금 벌어지는 문제의 대부분은 **LLM 에 대한 이해 부족**에서 옵니다.

- 알고 대처하면서 쓰면 **전혀 문제가 되지 않습니다.**
- 모르고 쓰면 엉성한 답변을 얻거나, 2.1 의 사례처럼 **심각한 피해**를 볼 수 있습니다.

**그래서 필요한 것은 더 좋은 모델이 아니라, 더 좋은 사용법입니다.**

- 이 세 가지 역설은 **뒤집으면 그대로 해법이 됩니다.** 3 장은 이 지점에서 시작합니다.

## 3. LLM 이해의 시작: 세 존재로 구별해서 대화하기

### 3.1 해법은 첫 번째 역설 안에 있습니다

2.2 에서 본 세 역설 중 **(1) 인간 우선 원칙**을 다시 보겠습니다.

LLM 은 기본적으로 **인간이 원하는 대로 답변하려는 태도**를 갖고 있습니다.

이것은 문제의 원인이면서, 동시에 **가장 강력한 도구**입니다. 왜냐하면 이런 뜻이기 때문입니다.

내가 원하는 것을 정확히 알려주기만 하면

-> LLM은 그것을 하려고 최선을 다한다: 아첨 문제가 크게 줄어든다

-> (2)번 "지식의 양의 역설"(일관성 없는 답변, 조용한 모호성 등)이 완화된다

-> (3)번 "효율의 역설"(무난한 답변)도 완화된다

### 문제의 핵심

- “내가 무엇을 원하는지”를 내가 먼저 아는 것입니다.
- 그런데 대부분의 사람은 그것을 의식하지 않고 요청합니다.

### 3.2 “무엇을 원하는가”는 사실 세 가지뿐입니다

LLM 에게 무언가를 요청할 때 사용자가 원하는 것은 대부분 셋 중 하나로 분류됩니다.

| 내가 원하는 것        | 이때 LLM 에게 기대하는 것                                    |
|-----------------|-----------------------------------------------------|
| 내 지식이 늘기를 원한다   | <b>스승</b> —내가 모르는 것을 가르쳐 주는 존재                      |
| 내 판단이 좋아지기를 원한다 | <b>동료</b> —나와 협력해 최선의 답을 함께 찾는 존재                   |
| 일이 처리되기를 원한다    | <b>일꾼</b> —내가 잘 알고 있는, 그러나 시간과 노력이 많이 드는 일을 대신하는 존재 |

- 이 셋은 **모델의 성능 차이가 아닙니다.**
- **같은 모델, 같은 대화창**에서 완전히 다른 응답을 원하는 것입니다.
- 그것은 **내가 어떤 관계를 설정했느냐**의 차이입니다.

그리고 저자의 경험상, LLM 은 **자신이 어떤 존재로서 답변을 요청받았는지를** 이해했을 때 가장 효과적으로 일합니다.

이를 위해 필요한 조건이 하나 있습니다.

**인간이 먼저, LLM 을 어떤 존재로 대할지 명확히 인지하고 있어야 합니다.**

**역할이 정해놓고 그것을 의식하면** 인간의 요청 (프롬프트) 이 일관성 있게 표현됩니다. 이런 표현의 일관성은 LLM 에게서 원하는 것을 얻고자 할 때 매우 중요합니다.

LLM 은 **강력한 언어 해석 능력**을 갖고 있기 때문에 **프롬프트 내 언어 표현에 사소한 차이가 생겨도 답변의 큰 차이**로 이어집니다.

### 3.3 왜 이 구분이 프롬프트를 바꿀까요

같은 상황 하나를 예시로 해서 세 가지 요청을 만들어 보겠습니다..

**상황:** 건강검진 결과지에 이해 안 되는 수치가 있습니다.

### (1) LLM 을 스승으로 인정하고 요청하기

>> 사용자:  
"이 항목이 무엇을 재는 건지 개념부터 설명해줘.  
수치 해석은 아직 하지 말고,  
이런 수치를 읽는 방법 자체를 먼저 알려줘."  
>> LLM:  
(그 항목의 의학적 의미와 읽는 법을 설명해 줌)  
>> 사용자가 얻는 것:  
(다음 검진 때는 결과를 혼자 이해할 수 있는 능력이 생김)

### (2) LLM 을 동료로 인정하고 요청하기

>> 사용자  
"내 해석은 이렇다. (내 생각을 먼저 적는다)  
이 해석의 문제점을 검토해 줘. (비판을 요청)  
다른 해석이 있으면 알려줘. (대안을 요청)  
의사와 상의해야 할 것들을 알려줘." (미래 대비책을 요청)  
>> LLM  
.... (이런 저런 설명들)  
>> 사용자가 얻는 것:  
(건강 관리에 관한 더 나은 판단력이 생김)

### (3) 일꾼으로 요청하기

>> 사용자:  
"이 결과지 항목들을 표로 정리해줘.  
정상 범위를 벗어난 항목만, 벗어난 정도 순으로.  
판단이나 조언은 하지 마."  
>> LLM:  
... 지시대로 작업 처리 후 표를 작성해서 제출 ...  
>> 사용자가 얻는 것:  
(시간과 노력을 절약)  
>> 사용자에게 아직도 남은 과제:  
(표가 정확한지는 사용자가 확인해야 한다)

### 경고:

- 건강검진 기록을 이해할 줄 모르면 표가 맞는지를 확인할 수 없습니다.

### (4) 정리하기

- 세 요청은 완전히 다른 문장입니다. 그리고 세 응답도 완전히 다릅니다.

그런데 대부분의 사람은 이렇게 씁니다.

(건강 검진 기록을 보여 주면서)  
"이것을 설명해줘"

이 요청은 셋 중 어느 것도 아닙니다.

- 그래서 2.2 “(2) 지식의 양의 역설”이 그대로 작동합니다—스승, 동료, 일꾼 역할에서 임의로 하나를 고르거나 아니면 마구 섞어서 응답합니다.
- 그러나 매우 그럴듯해 보이게 만들기 때문에 그걸 읽으면 **이해한 기분**이 듭니다.
- 그러나 다음 검진 때 똑같이 이해하지 못하고 LLM 에게 다시 도움을 요청해야 합니다.

**역할을 정하는 것이 곧 프롬프트를 정하는 것입니다.**

- 역할이 정해지면 무엇을 **어떻게 요청해야 할지**가 판단되기 시작합니다.

### 3.4 “LLM 을 써서 일을 했다”의 세 가지 의미—결과물로는 구분이 안 됩니다

여기서 이 구분이 왜 중요한지가 드러납니다.

| 상황                      | 눈앞의 결과물     | 나에게 남는 것               | 내 안에서 일어나는 변화  |
|-------------------------|-------------|------------------------|----------------|
| LLM 이 다 해줬고, 나는 읽고 넘어갔다 | <b>훌륭하다</b> | <b>없다</b>              | 점점 더 의존적인 존재   |
| LLM 에게 배워서, 내가 직접 했다    | <b>훌륭하다</b> | <b>혼자 할 수 있는 능력</b>    | 점점 더 발전하는 존재   |
| LLM 과 협력해서, 함께 했다       | <b>훌륭하다</b> | <b>효율적으로 할 수 있는 능력</b> | 점점 더 경쟁력 있는 존재 |

**결과물은 똑같습니다.**

- 겉으로는 구분이 안 됩니다.
- 그런데 3 개월 뒤에는 나는 완전히 다른 사람이 되어 있습니다.

#### LLM 을 쓸 때 항상 던져야 할 질문

- “LLM 에게서 무엇을 **얻었나**”에 만족하면 안 됩니다.
- “내가 무엇을 **배웠나**, 내가 **어떻게 발전했나**”를 확인해야 합니다.

### 3.5 세 역할 한눈에 보기

|                   | 스승              | 동료                     | 일꾼             |
|-------------------|-----------------|------------------------|----------------|
| <b>내가 얻는 것</b>    | 실력              | 더 나은 판단                | 시간과 노력을 절약     |
| <b>내가 해야 하는 것</b> | 배움에 시간과 노력을 투자  | 판단과 검증에 참여             | 확인할 책임         |
| <b>핵심 요청</b>      | “배울 수 있게 가르쳐 줘” | “내 생각은 이런데, 검증하고 보완해줘” | “이 조건과 지시대로 해” |

|        | 스승               | 동료                       | 일꾼                     |
|--------|------------------|--------------------------|------------------------|
| 성공한 결과 | 다음 번에는 혼자 할 수 있다 | 종합적이고 비판적인 사고력이 생긴다      | 의도한 것이 신속하고 정확하게 만들어진다 |
| 실패한 결과 | 이해한 기분만 남는다      | 자기중심적 또는 편향된 사고 방식이 생겨난다 | 나태하고 무책임한 사람이 되어 간다    |

#### 4. LLM 을 세 존재로 이해하기

이제 각 역할이 구체적으로 무엇을 해줄 수 있는지, 그리고 어떻게 요청해야 하는지를 보겠습니다.

- 읽는 동안 2.2 의 세 역설을 계속 떠올리기 바랍니다.
- 아래의 모든 요청법은 결국 세 역설 중 하나를 무력화하는 대화입니다.

##### 4.1 스승으로서—“부끄러운 질문을 할 수 있는 선생님이 24 시간 있습니다”

스승 모드가 무력화하는 역설: 주로 ① 번 (모르는 것은 요청할 수 없다) 과 ② 번 (수준 미정) 입니다.

##### (1) 같은 개념을 열 가지 방법으로 다시 설명합니다

교재나 강의는 설명을 한 번만 합니다. 이해가 안 되면 그 문장을 다섯 번 다시 읽는 수밖에 없습니다. LLM 은 각도를 바꿔서 다시 만들어 줍니다.

>> 나:  
"기회비용"을 설명해줘.  
>> LLM:  
(정의로 설명)  
>> 나:  
정의 말고, 내가 오늘 한 선택으로 예를 들어줘.  
>> LLM:  
오늘 3시간을 어떤 일에 썼다면, 기회비용은 "그 시간에 할 수 있었던 것 중 가장 가치 있는 하나"입니다.  
>> 나:  
그럼 아무것도 안 하고 쉬었으면 기회비용은 0이야?  
>> LLM:  
아닙니다. 그것도 선택입니다. 오히려...  
(납득이 될 때까지 이런 식의 대화를 계속 할 수 있다)

핵심은 “다시 설명해줘”가 아니라 “다른 방식으로 설명해줘”입니다.

- 이것이 ②번 역설 (수준·관점을 내가 정해준다)의 직접적 해법입니다.

#### 실제로 잘 듣는 요청:

- “비유 말고 구체적인 숫자로”
- “반대로 틀린 예시를 먼저”
- “중학생한테 하듯이”
- “한 문장으로 줄여줘”

#### (2) “남의 예제”가 아니라 “내가 만든 것”을 토대로 가르칩니다

교재의 예시는 남의 것입니다. LLM은 **지금 내가 할 수 있는 것**을 교재로 쓸 수 있습니다.

>> 나:

(내가 쓴 보고서 초안 붙여넣기)

고쳐주지는 말고, 이 글에서 내가 아직 잘 모르는 것 같은 또는 제대로 설명 못 하는 개념이 드러나는 곳이 있으면

>> LLM:

세 곳입니다.

2문단: 상관관계와 인과관계를 같은 것으로 쓰고 계십니다

4문단: 표본 편향을 고려하지 않았습니다

결론: 일반화 범위를 넘어선 주장입니다

방금 “내가 모른다는 사실조차 몰랐던 개념 세 개의 이름”을 얻었습니다. 이제 검색할 수 있습니다.

- 2.2 (1) 인간 우선의 역설에서 생기는 “모르는 것은 요청할 수 없다”라는 문제를 해결하는 거의 유일한 방법이 이것입니다.
- 스승의 가장 큰 역할은 답을 주는 게 아니라 **모르는 것의 이름을 알려주는 것**입니다.

#### (3) 연습 문제를 무한히, 난이도를 조절해가며 만들어 줍니다

>> 나:

이 개념으로 문제 5개 만들어줘. 쉬운 것부터 어려운 것 순서로.

답은 절대 주지 마. 내가 다 풀고 나면 그때 채점만 해줘.

#### 내 수준에 맞는 문제를 무한히 얻는 것:

- 시험이든 자격증이든 이만한 게 없습니다.

#### (4) 답 대신 질문을 줍니다 (요청하면)

>> 나:

이게 왜 틀렸는지 모르겠어.

“답 알려주지 말고”, 내가 스스로 찾게 질문만 해줘.

>> LLM:

“이 결론이 성립하려면 어떤 조건이 필요한가요?”

>> 나:

음... 표본이 무작위여야 해요.

>> LLM:

이 자료에서 표본은 어떻게 모였나요?

>> 나:

...아. 자원자만 모았네요.

찾아본 경험은 오래 기억에 남고, 받아 적은 답은 시간이 지나면 사라집니다.

- 여기서 “답 알려주지 말고”라는 문장이 결정적입니다.
- 이 문장이 없으면 (3) 효율의 역설에서 생기는 “무난한 답변 방식”이 작동해서, LLM은 그냥 정답을 알려주고 대화를 끝냅니다.

#### (5) 내 오답의 “패턴”을 진단합니다

한 번 틀린 건 실수지만, 세 번 이상 틀리는 건 **오개념**입니다. 그런데 내가 뭘 반복해서 틀리는지는 나 자신은 알아채지 못합니다 (헤매고 있으니까요).

>> 나:

오늘 대화에서 내가 헛갈렸던 부분들, 공통점이 뭐야?

>> LLM:

‘전체에 대해 참인 것’과 ‘각 개체에 대해 참인 것’을 계속 바꿔서 쓰고 계십니다. 세 번 같은 실수가 나왔습니다.

- **사람 선생님**이 학생 40 명에게 한 명씩 해주기는 현실적으로 어려운 일입니다.

#### (6) 벽을 낮춰 줍니다—영어 자료, 낯선 형식, 전문 용어

새로운 분야를 공부할 때 처음에 가장 힘든 이유는 대부분 **개념**이 어려워서가 아니라 **개념 자체를 아예 모르기 때문**입니다.

- 이런 문제를 보통 **진입 장벽**이라고 합니다.
- LLM은 **배움의 초기에 직면하게 되는 이런 진입 장벽**을 극복할 수 있게 해 줍니다.

| 막히는 것          | 이렇게 요청하면 됩니다                  |
|----------------|-------------------------------|
| 영어 논문 초록       | “배경 지식 없는 사람도 읽히게 풀어줘”        |
| 40 쪽짜리 약관·매뉴얼  | “내 상황에 해당하는 조항만 뽑아줘”          |
| 처음 보는 통계 표     | “각 열이 무슨 뜻이고 뭘 먼저 봐야 하는지 알려줘” |
| 서로 어긋나는 기사 5 개 | “왜 다르게 보도하는지, 어느 쪽이 최신인지 알려줘” |
| 보험·계약 조건문      | “내 조건에 걸리는 조항만 알려줘”           |

1 장에서 본 **LLM 의 넓이**가 실제로 도움이 되는 지점입니다.

#### (7) 창피한 질문을 마음껏 할 수 있습니다

“이거 물어보면 바보 같아 보일까?”

- 이 걱정 때문에 그냥 넘어간 것이 누구에게나 몇 개 있습니다. 그게 2~3 년 쌓이면 구멍이 됩니다.
- LLM은 판단하지 않고, 지치지 않고, 같은 질문을 다섯 번 해도 화내지 않습니다.
- 기술적으로는 사소해 보이지만, 실제 학습에서는 가장 큰 차이를 만듭니다.

[경고] 스승 모드의 함정: 배웠다는 느낌과 배운 사실은 다릅니다.

- **순환 루프의 함정:** “내가 제대로 배웠는지 판단”하려면
  - ① 이미 그걸 알고 있어야 합니다 (판단하기 위해서 필요합니다)
  - ② 그런데 나는 지금 배우는 중입니다 (배움은 과정입니다)
  - ③ 배울수록 모르는 것이 더 생깁니다 (정의와 설명은 다른 지식을 사용합니다)
  - … 배움은 이런 과정이 순환적으로 반복되는 것입니다…
- 그래서 확인은 **LLM 과의 대화 밖에서** 해야 합니다. 그것을 다음과 같이 할 수 있으면 배운 것입니다.
  - 혼자서 해보기
  - 교재·공식 문서와 대조해보기
  - 다른 사람에게 설명해보기
- **실천:** 뭔가 배웠다고 느끼면 LLM 과의 채팅창을 닫고 백지에서 다시 해보세요.
  - 못 하면 아직 안 배운 것입니다.

#### 4.2 동료로서—“내 생각의 사각지대를 채워줍니다”

**동료 모드가 무력화하는 역설:** 주로“(1) 인간 우선의 역설”의 동조 경향, 그리고“(3) 효율의 역설”의 무난한 답변입니다.

##### (1) 반대 의견을 주문 생산합니다

혼자 결정할 때 제일 위험한 건 내가 뭘 놓쳤는지 모른다는 것입니다.

>> 나:

당장 이직하려고 해.

이 선택 때문에 1년 뒤 “후회하게 될 상황 5가지”를 알려줘.

격려는 하지 마.

>> LLM:

(1) 지금 프로젝트가 이력서의 유일한 ‘완결’ 경험일 수 있습니다

(2) 재직 기간이 짧으면 다음 이직에서 반복 질문을 받습니다

(3) \*\*퇴직금·연차 정산 시점이 불리하게 걸릴 수 있습니다\*\*

(4) 이직 시장의 계절성을 고려하지 않으셨습니다

(5) 지금 불만의 원인이 회사가 아니라 직무일 수 있습니다

“업무 스트레스가 극심한 상황”이라면 3 번은 아마 생각 못 했을 것입니다. 그런데 실제로 제일 자주 문제가 되는 게 3 번입니다.

**주의해야 할 점:**

- “격려는 하지 마”라는 문장입니다.
- 2.2 “인간 우선의 역설”의 동조 경향을 명시적으로 차단하는 문장입니다.
- 이 문장이 없으면 같은 질문에도 “좋은 결정이십니다”로 시작하는 헛갈리게 하는 응답이 나올 수 있습니다.

##### (2) 내가 몰랐던 “선택지 자체”를 펼쳐 줍니다

혼자서 고민하면 내가 아는 방법 중에서만 고를 수밖에 없습니다.

>> 나:

이 문제를 해결하는 방법을 7가지 나열하고,

각각 어떤 상황에 맞는지 표로 만들어 줘.  
추천은 하지 마.

내가 알던 건 2 개였는데 7 개가 나옵니다. **선택지가 늘어난 다음의 고민이 진짜 고민입니다.**

**주의 사항:**

- “**추천은 하지 마**”가 중요합니다.
- 추천을 받는 순간부터 나는 **설득당하기 시작하고 판단을 넘기기 시작합니다.**
  - 원하는 **동료 모드**에서 원하지 않는 **스승 모드**로 전환되기 시작합니다.
- 그 문장의 또 다른 효과는 **(3) 효율의 역설**을 억제하게 만드는 것입니다.

### (3) 대답하는 고무 오리

“**고무 오리 디버깅**”이라는 말이 있습니다.

- 책상 위 인형에게 **소리 내어 설명**하다 보면 **스스로 답을 찾는 현상**입니다.
- 설명하려면 머릿속 논리를 순서대로 펴야 하는데, 그 과정에서 허점을 발견하게 되는 것입니다.

>> 나:

"발표 구성을 설명해볼게. 먼저 문제를 보여주고, 우리 해법을 보여주고, 마지막에 결과를 보여줄 거야. 그런데 결과가 제일 강한데 그걸 맨 뒤에... 아. 순서가 반대네"  
(허점을 발견하게 된다)

LLM 은 그 오리인데, **되물기까지 할 수 있는 오리**입니다.

- **LLM 은 아직 대답도 안 했습니다.** 설명하는 행위 자체가 문제를 풀었습니다.
- 설명을 듣고 나면, **LLM 은 문제점을 지적도 해줄 수 있습니다.**

### (4) 내가 인지하지 못했던 가정을 찾아 줍니다

>> 나:

이 기획안을 검토해줘. 단, 문장 다듬기 말고  
우리가 가정하고 있는데 "인식하지 못 해서 문서에는 안 적힌 것"만.

>> LLM:

- 참가자가 스마트폰을 항상 소지한다고 가정합니다
- 응답률이 50% 이상일 것으로 가정합니다
- 승인이 제때 날 것으로 가정합니다

**인지하지 못해서 말 안 한 가정은 나중에 문제를 일으킵니다.**

- 이걸 미리 표면으로 꺼내는 게 동료의 핵심 역할입니다.
- 2.2 “**지식의 양의 역설**”의 **조용한 모호성**을 내 문서에 대해 적용한 것이기도 합니다.

### (5) 아직 정돈되지 않은 어지러운 생각을 구조적으로 정리해 줍니다

>> 나:

(생각나는 대로 10줄 나열. 산만해도 상관없다)  
이걸 공통점 기준으로 3~4개 묶음으로 분류하고,  
각 묶음에 이름을 붙여줘. 내용은 절대 더하지 마.

인간이 기획할 때 초기에 겪는 어려움이 있습니다.

- 인간은 많은 아이디어 또는 생각들을 쉽게 할 수 있지만, 정리되기 전에는 그것들의 **구조적 또는 의미적 관계**를 잘 파악하지 못합니다.
- 그런 것들을 LLM 에게 분석시키면, 곧바로 구조적·의미적 지도를 만들 수 있습니다.
- 이런 기능은 **기획 작업에서 특히 강력합니다.**

#### (6) 낯선 분야로 연결하거나 확장할 수 있게 해 줍니다

LLM 에게 잘 모르는 “의료 용어, 회계 규정, 법률 조항, 공학 원리 등”에 대한 **1차 설명 또는 해석**을 요청해 즉시 받고, 그것을 토대로 곧바로 작업 계획을 만들라고 시킬 수도 있습니다. 필요하면 적절한 전문가에게 요청할 도움들도 정리하게 할 수 있습니다.

#### 주의 사항:

- LLM 을 과도하게 신뢰하면 안 됩니다. 여전히 전문가는 필요합니다.
- LLM 은 **전문가에게 도움을 요청할 수 있게 준비**를 시켜주는 것이지 전문가를 대체하지 않습니다.
- 2.1 에서 설명한 법정 사례가 대표적 오용 사례입니다.

#### (7) 갈등을 쟁점으로 바꿔 줍니다

>> 나:

A는 범위를 넓히자 하고, B는 마감을 지키자고 해.  
양쪽 주장을 각각 가장 강하게 정리해서 표로 만들어줘.  
\*누가 맞는지는 판단하지 마\*.

#### 감정 싸움이 논점 비교로 바뀝니다.

- LLM 의 “방대한 지식”을 바탕으로 **선입관과 사심 없이** 각 주장에 대해 구체적이고 체계적인 정리를 만들어 줍니다.
- **주의 사항:**
  - LLM 이 **응답 생성 중간에 판단**을 하게 되면 그 판단이 컨텍스트에 포함되는데, 이후에는 **컨텍스트에 근거하는 생성형 알고리즘 때문에** 그 판단에 편향된 선택을 하게 됩니다.
  - “누가 맞는지는 판단하지 마”는 **그런 편향된 선택을 하는 것을 방지**하려는 목적입니다.

#### 4.3 일꾼으로서—“지루한데 정확해야 하는 일”

다음과 같은 **흔히 속된 말로 “노가다 작업”**은 LLM 을 **일꾼 모드**로 사용하면 매우 효과적으로 처리할 수 있습니다.

- 그러나 **완결 조건과 검사 방법을 미리** 명확하게 결정해 놓아야 합니다.

| 예전에는                    | 지금은                     |
|-------------------------|-------------------------|
| 설문 응답 500 건을 손으로 분류: 하루 | 30 분 (내가 표본 검수를 하는 시간)  |
| 회의록 3 시간치를 정리: 반나절      | 15 분 (정리된 회의록을 검토하는 시간) |

|                       |                   |
|-----------------------|-------------------|
| 예전에는                  | 지금은               |
| 참고문헌 형식 40 개 통일: 2 시간 | 5 분 (형식을 확인하는 시간) |

### (1) 형식 번역—의미는 그대로, 형식과 구조만 바꾸기

잘 알려진 작업 예시들입니다.

- 발표 개요 → 보고서 문장
- 긴 글 → 슬라이드 뼈대
- 영문 → 국문
- 표 → 정리된 목록

**의미를 바꾸지 않고 형식만 바꾸는 일은 LLM 이 제일 안정적으로 잘하는 것입니다. 그리고 가장 많이 사용되는 영역이기도 합니다.**

- **결과가 맞는지 내가 바로 확인할 수 있는 일이기** 때문입니다.

### (2) 대량 나열

>> 나:

이 기획에서 실패할 수 있는 지점을 20개 나열해줘. 설명 말고 목록만.

>> LLM:

20개를 제시한다.

(20개 중 12개는 내가 생각 못 했을 것이다. "채택은 내가 한다.")

- 인간의 뇌는 특정한 것에 집중하는 데는 뛰어나지만 광범위한 범위에 걸쳐서 존재하는 다양한 것들을 동시에 찾아내서 정리하는 데는 취약합니다.
- 그러나 LLM 은 다양한 분야의 방대한 지식을 토대로 그런 종류의 요청을 처리하는 데 매우 효율적입니다.

### (3) 지저분한 자료 정리

여러 자료, 많은 자료에서 낱말 형식이 세 가지로 섞인 표, 중복 행, 이름에 공백이 붙은 항목 등의 문제점들을 찾아내어 정리합니다.

- **본 작업 시작 전에 항상 필요한 일입니다.**
- 그러나 인간은 이런 작업들을 잘하지 못하기도 하지만, 결정적으로 오랫동안 할 수가 없습니다.

그 이유는 분명합니다.

- 근본적으로 인간은 오랫동안 집중을 할 수 없습니다. **인간의 뇌는 쉽게 지치기 때문입니다.**
- 또한 인간은 복잡한 종류의 정보들을 동시에 처리하는 데 매우 취약합니다. 인간의 뇌가 여러 가지 정보를 동시에 처리하는 것을 잘 못 하기 때문입니다.

정반대로 LLM 은 **동시에 여러 종류의 정보를 처리하는 데 전혀 문제가 없고, 24 시간 1 년 내내 작업을 해도 지치지 않습니다.**

### (4) 초안 잡기

메일, 공지문, 회의 안건, 제안서 등의 작업을 할 때 사람들이 일반적으로 **많이 힘들어하는** 것이 초안을 작성하는 것입니다.

- **0 에서 1 을 만드는 비용**이 제일 비쌉니다.
- 그래서 **“시작이 반이다”**라는 속담이 나왔다고 봅니다.

LLM 은 의도, 목적 또는 방향과 범위만 정해주면 곧바로 초안을 만들어 줍니다.

- 물론 그대로 사용할 수는 없습니다. 그러나 비유적으로 **해야 할 일의 반, 즉 시작**을 LLM 이 즉시 해준 것입니다.

#### (5) “버릴 결과물”을 싸게 만듭니다

LLM 의 능력 중에서 일반적으로 사람들이 과소평가하는 것입니다.

예시: 기획안 만들기

- 예전에는 기획안 하나 만드는 데 많은 시간과 노력이 필요했습니다.
- 그래서 한 번 만든 것은 **아까워서 못 버렸습니다**. 부족한 점이 발견되더라도 다시 만드는 것이 쉽지 않기 때문에 계속 사용해야 했습니다.
- **문제점을 제거**하는 것이 아니라 **문제점을 보완**하는 데 많은 시간과 노력을 투입했습니다.

LLM 을 일꾼으로 사용하면 쉽게 여러 기획안을 만들어 보고 **세부적으로 비교 및 평가**를 하고 선택할 수 있습니다.

>> 나:

같은 목표를 세 가지 방향으로 각각 30분씩 만들어보고,  
직접 비교해보고, 두 개를 버린다.

- **세 개를 만들어보고 고르는 것과 하나를 만들어놓고 정당화하는 것은** 완전히 다른 일입니다.
- 판단력은 이런 비교 및 평가 경험에서 성장합니다.

#### (6) 일꾼 모드의 절대적 규칙

LLM 을 중요한 업무 (Mission-Critical Task) 에 활용하기 위해서는 **어떤 방식으로라도 LLM 의 응답을 검증**할 수 있어야 합니다. 따라서 LLM 을 일꾼으로 사용하기 위해서는 다음의 원칙이 지켜져야 합니다.

- **확인할 수 없는 것은 시킬 수 없습니다**: LLM 에게 일을 시키기 전에 응답을 검증할 수 있는 방법을 갖고 있어야 합니다.
- **LLM 에게 응답/결과에 대한 검증 규칙 또는 성공 조건을 알려 주어야 합니다**.
  - LLM 은 그것을 알고 있으면, 그것에 근거해서 답변을 만들어 냅니다.

#### 주목해야 할 점

- LLM 이 갖고 있는 **지식의 양의 역설**은 **학습되어 있는 방대하고 다양한 지식** 때문에 **“생성형 알고리즘으로 응답”**을 만들어 가는 과정에서 **선택지가 너무 많기 때문에** 발생 합니다.
- 미리 알려 주는 **검증 규칙 또는 성공 조건**은 LLM 에게 **사용자가 무엇을 원하는지**를 가장 확실하게 설명하는 방법일 수 있습니다.

- **검증 규칙 또는 성공 조건**은 “**생성형 알고리즘이 중간 과정에서 선택**”을 할 때 사용자의 의도를 반영할 수 있게 합니다.
- **검증 규칙 또는 성공 조건**은 “스승 모드”와 “동료 모드”에서도 어느 정도 효과를 볼 수 있는 방법입니다.

#### 주의해야 할 점: 자율과 통제 사이의 조율

- 그러나 **검증 규칙 또는 성공 조건**은 “스승 모드”와 “동료 모드”에서는 매우 정교하게 사용해야 합니다.
- 그 두 모드는 우리가 얻기를 원했던 것, **인간의 부족한 점을 채워주는 것**을 위해서 사용되어야 합니다. 그런데 **검증 규칙 또는 성공 조건**은 기본적으로 우리의 생각과 지시에 LLM 이 따르도록 강제하는 것입니다.
- 따라서 “스승 모드”와 “동료 모드”에서는 이 강의에서 강조하는 **자율과 통제** 사이에서 정교하게 조율되어야 합니다.

다음은 LLM 을 일꾼으로 사용할 때의 예시입니다.

“...그리고 나는 이것을 \*[이런 방법]\*으로 확인할 것이다.”

**이런 방법**의 예시입니다.

- “무작위 50 건을 내가 직접 검수한다”
- “원본 문서에서 인용 3 개를 직접 대조한다”
- “합계가 원자료 합계와 일치하는지 본다”

여기서 **[이런 방법]** 을 명확하게 줄 수 없으면 LLM 을 일꾼으로 사용할 수 없습니다.

- **2.1 (3) 의 변호사들**은 이런 요청을 하지 않았을 것입니다.

#### 4.4 세 역할은 번갈아 쓰는 것입니다

여기가 이 장에서 **가장 중요한 부분**입니다. LLM 의 역할은 **하나를 선택해서 고정하는 것이 아니라, 단계마다 바꾸는 것**입니다.

- 단순한 작업이 아니면 LLM 을 사용할 때 “일꾼”, “동료” 또는 “스승” 중에서 하나만으로 사용하는 경우는 거의 없습니다.
- 하나의 과제 안에서도 목적과 상황에 따라 계속 바뀌어야 합니다.

##### (1) 사용자 역량 관점에서 LLM 의 역할을 선택하기

세 가지 LLM 사용 방식은 기본적으로 **서로 독립적**입니다.

- 필요 또는 상황에 따라서 선택해서 사용해야 합니다.
- 어떤 모드가 다른 모드보다 절대적으로 좋거나 나쁘거나 하지는 않습니다.

그러나 **사용자의 역량 관점**에서 보면, 어느 정도 순서가 있다고 이해할 수 있습니다.

- **초보 수준:** 스승 모드가 효과적일 것입니다. (초반에 헤매고 있을 때)
- **중급 수준:** 동료 모드가 도움이 됩니다. (이제 어느 정도 자신감이 생겼을 때)
- **고급 수준:** 일꾼 모드가 적합합니다. (지시 방법과 결과 검증을 확실하게 알고 있을 때)

(2) 예시: 팀 과제—“우리 조직의 회의 문화 개선안”

| 역할                                            | 요청                                                                          | 응답                               | 활용              |
|-----------------------------------------------|-----------------------------------------------------------------------------|----------------------------------|-----------------|
| ① 스승                                          | “회의 비효율을 다루는 이론이 뭐가 있는지 개념 이름만”요청                                           | 처음 듣는 용어 3 개 확보                  | 공부할 방향 찾기       |
| ② 스승                                          | “그 개념에 관한 예제 문제”를 요청                                                        | 관련 예제 문제들                        | 혼자서 공부하기        |
| ③ 동료<br><br>“2 개는 진짜 문제, 3 개는 우리 규모엔 과함”이란 응답 | <b>내 조사 설계를 먼저 종이에 적음.</b> 그 다음 “이 설계가 후회될 상황 5 가지”요청<br>문제점 파악             | (LLM의 응답 이전<br>에 이미 발견)          | 내 생각을 점검        |
| ④ 동료                                          | 분석 논리를 말로 설명하다가 <b>특정 부서를 빠뜨렸다는 걸 스스로 발견</b>                                | 500 건 분류 결과 + 내가 검수할 무작위 50 건 표본 | 전문 작업을 위임       |
| ⑤ 일꾼                                          | “분류 기준을 먼저 제시하고 응답 500 건 1 차 분류”요청                                          | 깔끔하게 정리된 자료                      | 잡일을 맡김          |
| ⑥ 일꾼                                          | “발표 개요 작성, 보고서 형식 변환, 참고문헌 형식 통일 등”을 요청                                     | 내가 착각하고 있는 개념 두 개를 찾아줌           | 아직 이해 못 한 부분 파악 |
| ⑦ 스승                                          | <b>LLM 과의 대화창을 닫고</b> 핵심 논리를 <b>백지에서 혼자 정리해</b> 봄. 그리고 내가 아직 모르는 것이 있는지 질문함 |                                  |                 |

이 과제에서 **가장 중요한 LLM 사용 단계**는 “③ 동료”와 “⑦ 스승”입니다.

- ③ 번 단계: 내 생각을 **먼저** 정리해 본다. (동조 경향을 차단)
- ⑦ 번 단계: 배웠다고 **믿지 않고 확인**한다. (이해한 기분을 차단)

(3) 중요한 경고

METR이라는 연구기관이 2025년에 실험을 했습니다. **자기가 몇 년씩 관리해온 프로젝트**에서 일하는 숙련자 16명에게, 실제 업무 246건을 주고 LLM 사용 여부를 무작위로 배정했습니다.

|              | 값                       |
|--------------|-------------------------|
| 시작 전 본인들의 예상 | LLM 쓰면 <b>24% 빨라질 것</b> |
| 실제 측정 결과     | <b>19% 느려졌음</b>         |
| 끝나고 본인들의 체감  | <b>20% 빨라졌다고 느낌</b>     |

**충격적인 발견:** “전문가들마저도”자신의 분야에서 실제 상황과 반대로 느꼈습니다.

- 느려졌는데 빨라졌다고 느꼈습니다.
- 그것도 초보가 아니라 숙련자들이 그렇게 거꾸로 착각을 했습니다.

**이유 설명 (시간 차 때문에 일어나는 착시 현상): 결과 만들기 vs. 결과 검증하기**

- **전문가가 생산성이 향상되었다고 체감하는 이유: 심리적 만족감**
  - 지금까지는 전문가가 직접 작업을 수행해야 했기에 결과를 내기까지 많은 시간과 노력이 요구되었으나, LLM에게 작업을 맡기면 곧바로 결과가 나오기 때문에 생산성이 좋아졌다고 느낍니다.
- **회사에서 생산성이 악화되었다고 평가되는 이유: 검증 비용의 급증**
  - 요구되는 작업에 대한 지식과 경험이 충분한 전문가들이 결과를 내는 경우에는 완성도가 높을 수밖에 없습니다.
  - 그러나 LLM이 응답하는 결과에는 내부에 오류가 포함되는 경우가 자주 있는데, LLM이 결과를 매우 그럴싸하게 만들어 내기 때문에 검증하기가 매우 까다롭습니다. 그래서 사람이 작업할 때보다 오히려 검증 노력이 더 증가하게 됩니다.

#### 주의할 점

- 그러나 이 연구 결과를 **LLM이 느리게 만든다**로 단순하게 해석해서는 안 됩니다. 조건이 매우 특수했고 (대형 성숙 프로젝트, 초기 2025년 도구), 2026년 후속 실험에서는 참가자 편향에 관한 이슈도 지적되었습니다.
- 또한 **LLM과 AI Agent 등의 AI 기술이 매우 빠르게 발전**하고 있기 때문에 LLM 도입으로 인한 생산성은 계속 바뀔 수밖에 없습니다.

**진짜 교훈은 이것입니다:**

- 내가 잘하고 있는지에 대한 **내 느낌은 착시 효과일 수 있습니다.**
- 당장 눈앞에서 생기는 **그럴싸한 LLM의 응답에 만족하지 말고, 반드시 그 응답을 검증하는 데까지를 포함해서 판단**해야 합니다.

#### (4) 한 장 요약 (책상에 붙여두기)

**핵심 요약:**

- LLM 안에 있는 지식은 거대하다.

- 그러나 꺼내는 만큼만 내 것이 된다.

#### 자기 점검:

- LLM 대화창을 열기 전에 반드시 해야 할 자기 점검: 세 가지 역할을 구별해서 기억하기

[스승] 나는 배우길 원한다.

첫 마다: "답은 알려주지 말고, 문제를 이해시켜 주고, 방법을 습득하게 해줘"  
성취 조건: 대화창 닫고 혼자 할 수 있나?

[동료] 나는 내 생각을 검증하고 보완하길 원한다.

첫 마다: "내 생각은 이런데, 비판과 검증을 해주고 다른 대안도 제시해봐"  
성취 조건: 원래 생각의 문제점을 찾아내고 개선 방향을 찾아낼 수 있나?

[일꾼] 나는 작업을 맡기길 원한다.

첫 마다: "이 지시와 조건대로 실행해, 이렇게 검증하고 확인할 거야"  
성취 조건: 검증 절차를 만들 수 있고, LLM의 응답을 확인할 수 있나?

#### 주의 사항:

- 확인할 수 없는 것은 시킬 수 없다
- 장기적으로 가장 조용히 위험한 역할: 일꾼보다 스승. 배웠다는 착각은 눈에 보이지 않고 검증하기도 매우 어렵다
- 가장 못 믿을 근거: 내 느낌

## 5. LLM 이 아직 잘 못하는 것들은 무엇일까요?

능력을 제대로 알려면 **못하는 것도 정확히** 알아야 합니다. 이 장에서는 LLM 이 제대로 처리하지 못하는 것들이 무엇인지를 살펴보겠습니다.

- 어떤 것은 시간이 지나면 사라질 것으로, 어떤 것은 절대 사라지지 않을 것으로 예측됩니다.

#### 세 종류로 나눠 보기

| 유형                    | 성격                             | 시간이 지나면?               |
|-----------------------|--------------------------------|------------------------|
| <b>A. 능력의 한계</b>      | 지금 모델이 아직 못하는 것                | 상당 부분 <b>개선될</b> 것입니다  |
| <b>B. 구조적 한계</b>      | LLM 의 원리상 알 수 없는 것             | <b>사라지지 않습니다</b>       |
| <b>C. 사용자가 만드는 한계</b> | 2 장의 세 역설에 제대로 대처하지 못해서 발생하는 것 | 모델이 좋아져도 <b>그대로입니다</b> |

### 5.1 A. 능력의 한계—개선되는 중인 것들

| 약한 영역      | 어떻게 드러나나                            | 대처                             |
|------------|-------------------------------------|--------------------------------|
| 사실 확인      | 존재하지 않는 출처·인용을 <b>자신 있게</b> 만들어냅니다  | 원본과 대조. <b>일꾼 모드의 확인 절차</b>    |
| 정확한 수치 계산  | 도구 없이는 산수를 틀립니다                     | 계산은 도구/코드로 시키고 결과를 확인          |
| 긴 맥락 전체 유지 | 앞에서 정한 약속을 뒤에서 어깁니다                 | 중요한 제약은 <b>주기적으로 다시 명시</b>     |
| 진짜 새로운 문제  | 전례가 없으면 <b>비슷해 보이</b> 는 전례를 갖다 붙입니다 | <b>“이 사례에 명확한 근거가 있는지”</b> 되묻기 |

**사실 확인**이 가장 위험합니다.

- 2.1 (3) 의 법정 사례 전부가 여기서 나왔습니다. 그리고 이걸 “모델이 나빠서”가 아닙니다—LLM 은 **그럴듯한 문장을 만드는 장치**이고, 존재하지 않는 판례명도 형식적으로는 완벽하게 그럴듯합니다.
- LLM 응답의 그럴듯함과 사람의 나태함이 만나면 사실 확인이 제대로 못 하는 경우가 빈번하게 발생합니다. 멀리 갈 것도 없이 **이 강의자료도 여러 자료를 인용**하는데, 작업 중이라는 핑계로 일일이 확인하지 못 하고 있습니다.

### 5.2 구조적 한계—원리상 알 수 없는 것

| 약한 영역       | 왜 원리상 불가능한가                                                                                                  |
|-------------|--------------------------------------------------------------------------------------------------------------|
| 최신 정보       | 학습 시점 이후의 일은 <b>학습 자료에 없습니다</b> . 검색 도구를 붙이면 완화되지만, 그것도 100% 신뢰할 수 없기 때문에 결국은 <b>검색 결과의 신뢰성</b> 문제로 옮겨갈 뿐입니다 |
| 우리 조직·우리 사정 | 문서로 공개되지 않은 조직 내부 맥락은 <b>어디에도 기록되어 있지 않습니다</b> . 당연히 LLM 은 학습한 적이 없습니다                                       |
| 나의 목적·나의 제약 | 내가 말하지 않은 것은 알 수 없습니다                                                                                        |

두 번째와 세 번째 문제는 2.2 의 “(2) 지식의 양의 역설”과 간접적이지만 심각하게 연관됩니다.

- LLM 은 세상의 거의 모든 지식을 갖고 있지만, **나에 대해서는 내가 말한 것만** 압니다.

- 넓이와 깊이가 아무리 커도, **내 상황이라는 좁은 영역에서는 언제나 정보 부족 상태**입니다.
- LLM 은 필요한 정보가 없을 때 그것을 응답에서 밝히는 것이 아니라 자기가 갖고 있는 방대한 지식을 토대로 그럴싸한 응답을 만들어 냅니다.
- 최근에 Post-Training 을 통해서 이 문제가 개선되어 가는 것으로 보입니다.

이것이“**요청의 품질이 결과의 상한을 정한다**”는 명제의 근본 이유입니다.

### 5.3 사용자가 만드는 한계—모델이 좋아져도 사라지지 않습니다

| 약한 영역          | 어떻게 드러나나                         |
|----------------|----------------------------------|
| <b>동조 경향</b>   | “이거 맞지?”라고 물으면 대체로“맞다”고 합니다      |
| <b>조용한 모호성</b> | 모호한 결정을 알아서 채우고, 뭘 골랐는지 말하지 않습니다 |
| <b>무난한 답변</b>  | 적당히 요청하면 응답도 딱 그만큼만 나옵니다         |

이 셋이 2.2 의 세 역설입니다. 성능 문제가 아니라 **내가 어떻게 요청하느냐**의 문제이므로, **모델이 좋아져도 사라지지 않습니다.**

해결책은 이미 4 장 전체에서 봤습니다. 요약하면 세 문장입니다.

- “맞지?” -> “이게 틀렸다면 왜일까?”
- “정리해줘” -> “이 규칙과 조건대로 해줘, 이렇게 확인할 거야”
- “어떻게 생각해?” -> “내 생각은 이런데, 가장 강한 비판과 대안을 만들어줘”

### 5.4 혼한 오해

우리가 쉽게 착각할 수 있는 것이 있습니다.

- “모델이 더 좋아지면 이런 거 다 필요 없어지지 않나요?”

사실은 그 반대입니다.

- 모델이 좋아질수록 **더 크고 더 그럴듯한 결과물이 더 빨리** 나옵니다.
- 확인해야 할 양이 그만큼 **더 늘어납니다.**
- 그리고 5.3 에서 지적된 LLM 이 못 하는 세 가지는 성능과 무관합니다.

모델 능력 개선의 결과:

=> 결과물의 양과 그럴듯함도 증가

=> 따라서 확인의 부담 증가

결론:

=> 검증과 확인할 줄 아는 사람의 가치 증가

**확인할 수 없는 것은 시킬 수 없습니다.**

- 이 원칙은 모델이 좋아질수록 더 중요해집니다.
- 그리고 LLM 의 응답을 검증하고 확인할 줄 아는 사람이 되기 위해서는 **스승, 동료, 일꾼** 세 가지 방식을 모두 잘할 줄 알아야 합니다. 순서를 건너뛰지 않는 것입니다.

## 6. 자주 나오는 질문

### Q. 그럼 LLM 이 사람 전문가를 대체하나요?

- 아닙니다. 1.2 에서 본 것처럼 시험 점수는 **누구와 비교했는지에** 따라 크게 달라지고, 2.1 에서 본 것처럼 **확인 없이 쓰면 실제 피해**가 납니다.
- 정확한 표현은 “전문가를 대체하지는 않지만, **전문가로 성장하는 데 또는 전문가로서 일하는 데** 크게 도움이 된다”입니다.

### Q. LLM 안 쓰는 게 제일 안전한 거 아닌가요?

- 안전하지만 손해입니다.
- 특히 “스승 모드”를 포기하는 건 큰 손해입니다. 어떤 질문에도 즉시 답해주는 상대가 24 시간 있다는 건 이전 세대가 못 누린 커다란 혜택입니다.
- 문제는 **쓰느냐 마느냐가 아니라, 어떤 역할로 쓰는지 알고 쓰느냐**에 있습니다.

### Q. 세 역할을 매번 의식하는 게 피곤한데요.

- 의식해서 생기는 피곤보다 **의식하지 않아서 생기는 피곤**이 비교할 수 없을 정도로 큼니다.

### Q. 프롬프트 잘 쓰는 법을 따로 배워야 하나요?

- 기교보다 **역할 인식**이 먼저입니다.
- 이 문서의 3 장 하나가 이른바 “프롬프트 팁” 목록보다 실전에서 크게 작동합니다.
- 무엇을 원하는지가 정해지면 프롬프트 문장은 따라옵니다.

### Q. 1 장의 “거의 만능”이라는 표현은 과장 아닌가요?

- 지적 능력의 **범위**에 한정된 표현이고, 1.3 에서 밝힌 대로 “곧 만능이 된다”는 부분은 **논쟁적 예견**입니다.
- 다만 “여러 분야에서 전문가 평균을 넘어섰다”와 “그 조합을 인간은 가질 수 없다”는 두 가지는 지금 시점에서도 사실로 보입니다.

## 부록. 더 알아보기

| 주제                    | 어디서                                                                                                                                   |
|-----------------------|---------------------------------------------------------------------------------------------------------------------------------------|
| GPQA 원 논문 (전문가 수준 시험) | <a href="https://arxiv.org/abs/2311.12022">https://arxiv.org/abs/2311.12022</a>                                                       |
| 변호사 시험 점수 재분석         | <a href="https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4441311">https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4441311</a> |

| 주제                                  | 어디서                                                                                                                                                                                                                                                                       |
|-------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| AI 환각 관련 법원 제재 동향 정리                | <a href="https://www.nortonrosefulbright.com/en-us/knowledge/publications/792d8bf3/ai-in-litigation-update-on-gen-ai-sanctions-in-2026">https://www.nortonrosefulbright.com/en-us/knowledge/publications/792d8bf3/ai-in-litigation-update-on-gen-ai-sanctions-in-2026</a> |
| 실제 사용 분포 (Anthropic Economic Index) | <a href="https://www.anthropic.com/news/the-anthropic-economic-index">https://www.anthropic.com/news/the-anthropic-economic-index</a>                                                                                                                                     |
| 최신 사용 동향 보고서                        | <a href="https://www.anthropic.com/research/economic-index-june-2026-report">https://www.anthropic.com/research/economic-index-june-2026-report</a>                                                                                                                       |
| METR 생산성 연구 원문                      | <a href="https://metr.org/blog/2025-07-10-early-2025-ai-experienced-os-dev-study/">https://metr.org/blog/2025-07-10-early-2025-ai-experienced-os-dev-study/</a>                                                                                                           |
| METR 후속 실험 유보 발표                    | <a href="https://metr.org/blog/2026-02-24-uplift-update/">https://metr.org/blog/2026-02-24-uplift-update/</a>                                                                                                                                                             |