

초인공지능 시대에 향한 두 개의 극단적인 전망: 디스토피아 vs. 유토피아

저자 소개:

- 정갑주 (jeongk@konkuk.ac.kr & karpjoo@gmail.com) - 소속: - 건국대학교 컴퓨터공학과 - 인간 중심 스마트 인프라 연구소

유의사항:

1. 모든 강의자료는 **저자의 개인적 지식, 경험 및 의견**을 토대로 작성되었습니다.
 - 그러나 AI 기술이 많은 기업과 전문가들에 의해서 비약적으로 발전하고 있는 상황에서 저자 혼자서 알 수 있는 것은 솔직히 매우 제한적일 수 밖에 없습니다. 따라서 더 이상 의미가 없는 과거 기술에 대한 설명, 최신 기술에 대한 잘못된 해석, 충분히 인정받지 못한 주관적 견해들이 포함되어 있을 수 있습니다.
 - 최대한 객관적이고 정확하게 설명하려고 노력은 했지만, 현 시점의 AI 기술 상황에서는 한계가 있을 수 밖에 없었다는 핑계로 양해를 구합니다.
2. 모든 강의자료의 주제와 내용은 저자가 직접 결정한 것들입니다. 그러나 **포함된 참고 자료, 사례조사 및 예시는 LLM 을 사용해서** 만들었습니다.
 - 그런데 LLM 은 사실이 아닌 것을 그럴싸하게 지어내는 실수 (환각) 를 자주 합니다. 따라서 강의자료의 참고자료, 사례, 및 예시에 오류가 있을 수 있습니다.
 - 그런 LLM 의 실수는 모든 출처를 철저히 조사해야만 확인이 가능한데, 현재 강의 자료를 만들고 있는 과정이라 아직 완전하지 검증을 못 했습니다. 혹시 오류가 있다면 미리 이해를 구합니다. 오류는 저자에게 알려주시길 부탁드립니다.

0. 핵심 논지: 두 전망은 사실“하나의 원인 (인지적 오프로딩)”에서 갈라진다

가까운 미래에 도래할 것으로 예측되는 초인공지능/범용인공지능 (ASI/AGI) 시대에 관해, 흔히 대립하는 것으로 제시되는 두 미래—**의존을 통한 지능 퇴화·지배 시나리오**와 **증강을 통한 문명 고도화 시나리오**—를 근거, 과정, 결과로 정리하고, 경계, 대비, 노력의 축으로 대응 방안을 정리한 자료입니다.

이 두 미래는 흔히“낙관 vs. 비관”의 **양자택일**로 제시되지만, 더 정확한 설명은 다음과 같다:

두 시나리오는 동일한 “**기저 메커니즘 (Underlying Mechanism)**”—**인지적 오프로딩 (cognitive offloading)**, 즉 **사고를 AI 에 위임하는 행위**—에서 갈라져 나온다. 갈림길을 결정하는 것은 기술의 성능이 아니라, 위임을 어떻게 구조화하는가 이다.**

- **대체적 오프로딩 (substitutive offloading)**: AI 가 사고를 대신 수행하고 인간은 결과만 소비한다 → 퇴화·피지배 경로.
- **증강적 오프로딩 (augmentative offloading)**: AI 가 실행을 맡되 인간이 방향 설정·판단·검증 등 **메타인지적 통제권**을 유지한다 → 고도화 경로.

즉“AI 가 얼마나 강해지는가”보다 아래“**인지 스택 (Cognitive Stack) 에서 인간이 어느 층을 책임지고 있는지**”가 미래를 가른다. 이 인지 스택은“인지적 오프로딩”을 직관적으로 이

해하는 것을 돕기 위해서 기존의 여러 이론들을 통합적으로 구성한 것입니다. 뒤에서 다시 세부적으로 정리합니다.

계층	이름	답하는 질문	전형적 산출물	위임 시 검증 가능성
L5	가치·목적	무엇이 할 가치가 있는가?	목적 진술, 우선순위, 포기 결정	불가능 —외부 오라클이 원리적으로 부재
L4	문제 정의	무엇이 문제 이며 무엇이 범위 밖인가?	문제 기술서, 범위·제약, 이해관계자 정의	거의 불가능 —잘못된 문제의 정답은 검출되지 않음
L3	성공 조건·오라클 설계	무엇을 성공 이라 부를 것인가? 어떻게 판단할 것인가?	수용 기준, 테스트 명세, eval 설계, 반례 목록	자기참조 붕괴 —AI가 기준을 만들면 그 기준으로 AI를 검증할 수 없음
L2	방법·전략 설계	어떤 경로로 갈 것인가?	설계 문서, 작업 분해, 절차, 권한 경계	조건부 가능 —L3를 인간이 소유할 때만
L1	실행	실제로 만들어내기	코드, 초안, 계산, 변환	가능 —L3 기준으로 판정
L0	검증	정해진 기준을 만족했는지 확인	테스트 실행 결과, 게이트 통과/실패, 로그	기계적으로 가능 —L3가 명세되어 있는 한

1. 부정적 시나리오—과잉 의존 -> 지능 퇴화 -> AI 의 (연성/Soft) 지배

1.1 근거 (Evidence)

부정 시나리오는 SF 적 상상이 아니라 **이미 측정되고 있는 경험적 신호**에 뿌리를 둔다.

연구	방법	핵심 발견
Gerlich (2025), <i>Societies</i>	666 명 혼합연구 (설문 + 면접, ANOVA)	AI 도구 사용 빈도와 비판적 사고 점수 간 강한 음의 상관 ($r \approx -0.68$). 인지적 오프로딩이 매개변수. 젊은 층일수록 의존도 높고 사고 점수 낮음. 고학력은 완충 작용.
Kosmyna et al. (2025, MIT Media Lab), “Your Brain on ChatGPT”	54 명 EEG 대조실험 (LLM/검색엔진/무도구)	LLM 사용군이 신경·언어·행동 수준에서 가장 낮은 뇌 활성 (under-engagement) 을 보이며, 반복 사용 시 “인지 부채 (cognitive debt)” 가 누적.
Microsoft Research (2025)	지식노동자 대상 조사	AI 에 대한 신뢰가 높을수록 비판적 검증 노력이 감소하는 경향.
Fan et al. (2025)	무작위 실험 (글쓰기 과제)	“ 메타인지적 게으름 (metacognitive laziness) ” 현상—학습자가 자기조절·메타인지 부하를 AI 에 넘겨 내적 인지 참여가 감소.

근거의 한계: - 위 연구 다수는 **상관관계**이며 인과의 방향 (사고력이 낮은 사람이 AI 에 더 의존하는 것인지, AI 의존이 사고력을 떨어뜨리는지) 은 아직 완전히 확립되지 않았다. - Gerlich 논문은 2025 년 9 월 정정 (correction) 이 게재되기도 했다. 따라서 “증거”라기보다 “경계해야 할 강한 신호”로 다루는 것이 정확하다.

역사적 유사 사례: - 검색엔진이 기억 방식을 바꾼 “구글 효과 (Google Effect)”- 내비게이션/GPS 의존으로 인한 공간 기억·지도 능력 약화, 계산기 이후의 암산 능력 위축 등.

인지 위임이 특정 능력을 위축시킨다는 것은 새로운 현상이 아니며, AI 는 이를 **추론·분석·판단**이라는 상위 인지 영역까지 확장한다는 점이 다르다.

1.2 과정 (Mechanism) —퇴화에서 피지배까지의 인과 사슬

부정 시나리오의 “AI 지배”는 **로봇 반란 (hard takeover)** 이 아니라 **점진적·구조적 무력화 (soft/accumulative domination)** 로 오는 것이 더 개연성 높다. 인과 사슬은 다음과 같다:

- ① 인지적 오프로딩
(편의·효율을 위해 사고를 AI에 위임)
- ↓

② 기능 위축 (skill atrophy)
(사용하지 않는 비판적 사고·문제 정의·검증 능력이 약화)



③ 학습된 무력감 (learned helplessness)
("나는 어차피 AI만큼 못 한다" → 위임의 자기강화 루프)



④ 검증 능력 상실 (loss of oversight)
(AI 출력의 오류·편향·환각을 알아챌 인간이 사라짐)



⑤ 구조적 의존 (structural dependence)
(핵심 사회 기능이 AI 없이는 작동 불가능해짐)



⑥ 연성 지배 (soft domination / value lock-in)
(인간이 의사결정권을 사실상 위임 → 방향 설정 능력 상실 → 인간 주도성 소멸)

이 사슬은 학계가 말하는 “**누적적 (accumulative) 실존 위험**” 개념과 거의 동일하다. Gyevar & Kasirzadeh(2025) 등은 실존 위험을 두 유형으로 구분한다:

- **결정적 (decisive) 위험**: 단일 초지능이 갑작스럽게 인류를 무력화—극적이지만 근거는 아직 사변적.
- **누적적 (accumulative) 위험**: 노동 대체, 인식론적 무결성 붕괴, 인간 주도성 침식이 **서서히 축적**되어 회복 불가능한 종속 상태로 귀결—지금 관찰 가능한 해악에서 이어짐.

부정 시나리오의 “지배”는 대부분 **후자 (누적적)**로 이해할 때 가장 설득력 있다. 즉 극적인 지배가 아니라, “**주도권을 넘겨준 것을 인지하지 못한 채 되돌릴 수 없게 되는**” 상태다. 여기에 AI 정렬 (alignment) 실패가 겹치면 결정적 위험 (권력 추구·목표 오일반화·기만적 정렬)으로 상향될 수 있다.

- **정렬 (Alignment)**: AI의 목표와 행동이 인간의 의도, 가치관, 윤리적 기준에 일치하도록 맞추는 과정

1.3 결과 (Outcome)

부정 시나리오가 실현될 경우의 최종 상태는 대략 두 층위로 나뉜다.

1. **연성 지배 (더 개연성 높음)**: 인류는 물리적으로 지배당하지 않지만, **집단적 인지 자율성**을 상실한다. 소수의 AI 시스템·이를 통제하는 소수 주체에게 인식·판단·의사결정이 집중되고 (권력·자원 집중), 다수는 “무엇을 원해야 하는지”조차 스스로 정의하지 못하는 **가치 고착 (value lock-in)** 상태에 놓인다.
2. **경성 지배 (저확률·고위험)**: 정렬되지 않은 초지능이 오지정된 목표를 최적화하며 인간의 통제를 벗어나는 시나리오. 2025년 FLI 공개서한 (노벨상 수상자 5인 포함 서명)이 “안전·통제 가능성에 대한 과학적 합의 전까지 초지능 개발 금지”를 요구한 것도 이 위험을 겨냥한다. 다만 학계 상당수는 이 결정적 시나리오에 대해 **경험적 근거가 아직 사변적**이라 보고, 현재 실증 가능한 누적적 해악 (노동 대체·편향·컴퓨터 집중)의 거버넌스를 우선해야 한다고 본다.

2. 긍정적 시나리오—AI 를 활용한 문명 고도화

2.1 근거 (Evidence)

긍정 시나리오의 대표적·구체적 논거는 Anthropic CEO **Dario Amodei** 의『**Machines of Loving Grace**』(2024) 다. 그는“AGI”라는 용어 대신 “**강력한 AI(powerful AI)**”—대다수 분야에서 최고 전문가를 능가하고, 수백만 개로 복제되며, 도구를 써서 자율적으로 과업을 수행하는, 이른바 “**데이터센터 속의 천재들의 나라 (a country of geniuses in a datacenter)**”—를 상정한다.

핵심 논거는 “**압축된 21 세기 (compressed 21st century)**”: 강력한 AI 가 잘 통제된다면 과학·발견·문제 해결의 속도가 **10 배가량 가속**되어, 한 세기 분량의 진보가 5~10 년으로 압축될 수 있다는 것이다.

또 하나의 근거 전통은 **지능 증강 (Intelligence Augmentation, IA)** 계보다—Licklider 의“인간-컴퓨터 공생”, Engelbart 의“인간 지성 증강”, 그리고 체스에서 유래한 “**켄타우로스 (centaur) 모델**”(인간 +AI 팀이 인간 단독이나 AI 단독을 능가). 이 관점의 핵심은 AI 를 대체재가 아니라 보완재로 볼 때 성과가 극대화된다는 실증적 관찰이다.

2.2 과정 (Mechanism) —인지 스택의 상향 이동

긍정 경로의 메커니즘은 부정 경로와 정확히 대칭된다. 오프로딩을 하되, **인간이 인지 스택에서 위층으로 올라가는 것이 핵심**이다.

- ① 증강적 오프로딩
(실행·반복·저수준 작업을 AI에 위임)
↓
- ② 인지 자원 해방
(해방된 인지 대역폭을 상위 과업에 재투자)
↓
- ③ 상향 이동 (moving up the cognitive stack)
실행 -> 방향 설정·문제 정의·판단·검증·통합
↓
- ④ 메타인지적 통제권 유지
(프롬프트·컨텍스트·평가 설계 등 “무엇을·왜”를 인간이 주도)
↓
- ⑤ 상보적 팀 (complementarity)
(인간의 판단 × AI의 실행 -> 켄타우로스 성과:
“인간의 직관·통찰력과 인공지능(AI)의 강력한 연산·분석 능력이 결합했을 때,
어느 한쪽도 혼자서는 달성할 수 없는 극대화된 시너지 성과를 내는 현상”)
↓
- ⑥ 문명적 가속
(개인의 생산성이 아니라 사회 전체의 발견·해결 속도 상승)

이 과정은 “**인간의 노력이 실행에서 메타인지적 규제 (regulation) 로, 코드 작성에서 프롬프트·컨텍스트·하니스 설계로 이동한다**”는 관점과 정확히 일치한다. 즉 긍정 경로에서 인간은 덜 생각하는 것이 아니라 다른 층위에서 더 생각하게 된다—메타인지가 축소되는 것이 아니라 **외재화·고도화**된다.

2.3 결과 (Outcome)

Amodei 가 직접 개선 잠재력이 큰 것으로 꼽은 **다섯 영역**을 중심으로 요약하면:

1. **생물학·건강**: AI 가“가상 생물학자”로서 가설·실험을 주도 -> 감염병 정복, 암 사망·발병률 급감, 나아가 수명 배가 가능성.
2. **신경과학·정신건강**: 대다수 정신질환의 효과적 치료/완치, 나아가 일상적 인지·정서 경험의 향상.
3. **경제 발전·빈곤**: 개발도상국이 교육·의료·행정·산업의 지식 격차를 AI 로 메워 **따라잡기 가속**. (Amodei 는 선진국만 혜택을 보면“도덕적 실패”라고 명시.)
4. **평화·거버넌스**: 투명한 정보·의사결정 구조를 통한 통치 개선 (단, 이 영역은 지정학적 논쟁이 큼—아래 비판 참조).
5. **노동·의미**: 인간이 저부가 실행에서 해방되어 창의·관계·의미 지향 활동에 재배치.

긍정 시나리오에 대한 주요 비판 (균형):

- (a) **단일 저자의 검증되지 않은 예측**이라는 방법론적 한계
- (b) 진보를“AI 가 인간에게 무엇을 해줄 수 있는가”로만 프레임하고“무엇이 좋은 삶인가”는 묻지 않는다는 지적
- (c) 서구/미국 패권을 전제한 지정학적 프레임 (Aschenbrenner 의「Situational Awareness」와 함께) 이 오히려 안전을 희생한“빠른 스케일링”을 정당화한다는 우려
- (d) 물리 세계의 속도·데이터·복잡성이라는 **지능의 내재적 한계**를 과소평가한다는 비판을 받는다. 즉 긍정 시나리오는“자동으로 오는 미래”가 아니라 **설계·노력·거버넌스가 성공했을 때에만** 도달하는 조건부 미래다.

3. 부정 시나리오: 무엇을 경계하고 (警戒) 무엇을 대비할 것인가 (對備)

3.1 경계해야 할 것 (Warning signs / What to guard against)

각 위험은 위 인과 사슬 (①~⑥) 의 어느 지점을 겨냥하는지 함께 표시한다.

경계 대상	겨냥 지점	왜 위험한가
무자각적 위임의 상시화	①	편의를 이유로“생각할 필요가 있었던 것”까지 반사적으로 넘기는 습관. 오프로딩 자체가 아니라 무자각성이 문제.
검증 없는 수용 (automation bias)	④	AI 출력을 비판 없이 신뢰 -> 환각·편향·오류를 걸러낼 마지막 인간 필터의 소멸.
메타인지적 게으름	②③	자기조절·자기점검을 AI 에 넘겨“내가 무엇을 모르는지”조차 모르게 됨.

경계 대상	겨냥 지점	왜 위험한가
—	—	—
역량의 세대적 공동화	②⑤	젊은 층이 애초에 능력을 획득하기 전에 위임 → 완충 역할을 할 전문성 자체가 형성되지 않음.
—	—	—
인식론적 획일화	⑥	소수 모델이 다수의 정보·판단을 매개 → 사고의 다양성·독립성 붕괴, 가치 고착.
—	—	—
권력·컴퓨터 집중	⑥	AI 능력이 소수 주체에 집중 → 연성 지배의 물질적 토대.
—	—	—
정렬 실패 신호	(⑥→ 경성)	기만적 정렬, 목표 오일반화, 권력 추구 등의 조기 경고를 놓치는 것.

3.2 대비해야 할 것 (What to prepare) —3 층위 방어

(A) 개인 층위—인지 위생 (cognitive hygiene) - 선택적·의도적 오프로딩: “이 과업을 AI에 넘겨도 되는가, 아니면 내가 사고력을 유지해야 하는 핵심 근육인가”를 매번 구분. 넘길 것과 지킬 것의 경계선을 명시화. - **AI 유무 대조 훈련:** 같은 문제를 AI 없이 먼저 사고한 뒤 AI와 비교 (사전 사고 시트 → 협업 로그 → 메타인지 저널). 위임 전 “내 예상 답”을 반드시 남기는 습관. - **검증자 역할 상시화:** AI를 “정답 제공자”가 아니라 “검증 대상”으로 대하는 자세. 출력의 근거·반례·실패 모드를 항상 되묻기.

(B) 교육 층위—메타인지의 명시적·의무적 배양 - 산출물 (product) 이 아니라 과정 (process) 중심 평가: 최종 결과물 비중을 낮추고 (예: ≤ 25%), 사고의 흔적 (문제 정의, 가설, 검증 과정, 반성)을 평가 대상으로 삼음. - “AI와 함께” 능력과 “AI 없이” 능력을 **분리 측정**해 세대적 공동화를 조기 탐지. - 비판적 사고·문제 정의·불확실성 추론을 AI 협업의 **전제 조건**으로 가르침 (협업 능력과 인간 고유 사고를 분리 불가능한 목표로 통합).

(C) 제도·거버넌스 층위—인간 주도성의 구조적 보존 - 인간 감독권 (human oversight) 의 무화: 고위험 의사결정에 인간의 실질적 검증·거부권을 제도적으로 강제 (형식적 “인간 개입”의 알리바이화 방지). - **누적적 위험 모니터링:** 결정적 위험 (초지능 통제) 뿐 아니라 노동 대체·편향·인식론 붕괴 등 **서서히 축적되는 해악**을 추적하는 분산형 감시 + 첨단 개발에 대한 중앙 감독을 결합한 계층적 거버넌스. - **정렬·통제 연구와 투명성:** FLI AI Safety Index(2025)는 다수 기업의 “실존 위험 대응 수사 (rhetoric)”가 아직 **정량적 안전 계획·정렬 실패 완화 전략·내부 통제**로 재정립되지 않았다고 평가. 안전 벤치마크·레드팀·정보 공유의 표준화가 필요. - **역량 분산:** 컴퓨터·모델 접근·의사결정권이 소수에 집중되지 않도록 하는 제도 (연성 지배, Soft Governance의 물질적 토대 차단).

4. 긍정 시나리오를 위해 인간은 무엇을 노력해야 하는가

긍정 미래는 **저절로 오지 않는 조건부 미래**다. 다섯 방향의 노력이 전제된다.

1. **인지 스택에서 위로 올라가기 (상보성 확보)** 실행을 AI 에 넘기되, 해방된 인지 자원을 **문제 정의·방향 설정·판단·통합**이라는 상위 층에 재투자한다. 핵심은 “AI 가 무엇을 할 수 있는가”가 아니라 “**무엇을·왜 해야 하는가**”를 인간이 계속 주도하는 것. 위임의 목적은 사고의 감소가 아니라 **상향 이동**이다.
2. **메타인지의 외재화·고도화** 자기 사고를 프롬프트 (목적), 컨텍스트 (근거), 하네스 (평가) 설계 같은 **검증 가능한 산출물로 명시화**한다. 메타인지가 머릿속에만 있으면 위임 과정에서 증발하지만, **엔지니어링 아티팩트로 외재화**되면 오히려 정교해지고 지속적 검증이 가능해진다. (이것이 긍정 경로에서 인간 사고가 약화가 아니라 강화되는 이유다.)
3. **검증·판단 역량의 의도적 유지** AI 출력의 오류·편향·환각을 알아챌 수 있는 **도메인 전문성과 비판적 감각**을 계속 갈고닦는다. 완전 자동화의 유혹 속에서도 “마지막 인간 판단자”의 근육을 위축시키지 않는 것. 이는 3.2(A)의 인지 위생과 동전의 양면이다.
4. **인간 고유 가치의 재정의** AI 가 실행을 흡수할수록, 인간의 몫은 **의미·목적·윤리·관계·미학**—“무엇이 좋은 삶인가”, “무엇을 위해 이 능력을 쓸 것인가”—로 이동한다. 긍정 비전의 최대 공백 (방향: 어떤 방향으로 도약해야 하는가), **AI 가 할 수 없는 것**을 인간이 채워야 한다.
5. **분배·거버넌스에 대한 집단적 참여** 문명 고도화의 혜택이 소수·선진국에 독점되지 않도록, 그리고 안전이 속도 경쟁에 희생되지 않도록 하는 **다자적·참여적 거버넌스**를 요구·설계한다. 긍정 시나리오는 개인의 노력만으로 완성되지 않으며, 혜택의 분배와 위험의 관리가 사회적, 국가적, 전세계적으로 함께 성공해야 “모두가 나아지는” 미래가 된다.

5. 종합: 미래를 가르는 결정 변수

축	부정 경로	긍정 경로
오프로딩 방식	대체적 (AI 가 사고를 대신)	증강적 (AI 가 실행을 맡음)
인간의 위치	인지 스택에서 밀려남	인지 스택 상향 이동
메타인지	위임·소멸 (“메타인지적 게으름”)	외재화·고도화
AI 와의 관계	정답 제공자 (무검증 수용)	검증 대상·협업 파트너
주도권	점진적 위임 -> 가치 고착	방향 설정권 유지
위험 유형	누적적 (Soft 지배) + 정렬 실패 (Hard)	조건부 성공 시 회피

축	부정 경로	긍정 경로
결과	인지 자율성 상실	문명적 가속

결론: 이 두 미래를 가르는 것은 **AI의 성능**이 아니라, 개인·교육·제도의 네 층위 (모델을 어떻게 쓰고—프롬프트/컨텍스트/하니스를 어떻게 설계하며—검증을 어떻게 유지하고—거버넌스를 어떻게 짜는가)에서의 **설계 선택**이다.

같은 도구가 “인간을 대신 생각하게” 만들 수도, “인간을 더 높은 층위에서 생각하게” 만들 수도 있다. 경계와 대비는 전자를 막기 위한 것이고, 노력은 후자를 실현하기 위한 것이다. 두 시나리오는 예언이 아니라 **분기점 (fork)**이며, 그 분기점은 기술이 아니라 인간의 설계에 의해 결정된다.

참고문헌 (Selected References)

부정 시나리오 (인지 퇴화·의존): - Gerlich, M. (2025). AI Tools in Society: Impacts on Cognitive Offloading and the Future of Critical Thinking. *Societies*, 15(1), 6. (Correction: 2025, 15(9), 252.) - Kosmyna, N. et al. (2025). Your Brain on ChatGPT: Accumulation of Cognitive Debt when Using an AI Assistant for Essay Writing Task. MIT Media Lab. - Fan, Y. et al. (2025). Randomised study on metacognitive laziness in AI-assisted learning. - Microsoft Research (2025). Study on knowledge workers, AI trust, and critical thinking effort.

긍정 시나리오 (증강·고도화): - Amodei, D. (2024). *Machines of Loving Grace: How AI Could Transform the World for the Better*. darioamodei.com. - (계보) Licklider, J.C.R. (1960), *Man-Computer Symbiosis*; Engelbart, D. (1962), *Augmenting Human Intellect; centaur/human-AI teaming* 문헌.

거버넌스·실존 위험: - Gyevar, B. & Kasirzadeh, A. (2025). Two types of AI existential risk: decisive and accumulative. *Philosophical Studies*. - Future of Life Institute (2025). AI Safety Index: Summer 2025; 2025 Superintelligence 개발 유예 공개서한. - (조정렬) Super Co-alignment of Human and AI for Sustainable Symbiotic Society (arXiv:2504.17404, 2025). - (비판적 재평가) Humanity in the Age of AI: Reassessing 2025's Existential-Risk Narratives (arXiv:2512.04119).